



ADAPTIVE AND PERSONALIZED EXERCISE GENERATION FOR ONLINE LANGUAGE LEARNING

INTEGRANTES: TOMÁS LOBO - MARTÍN RAMÍREZ - AMANDA SANDOVAL

CONTENIDO

01

DEFINICIÓN Y MOTIVACIÓN DEL ESTUDIO

02

TRABAJOS RELACIONADOS

03

MÉTODOS PROPUESTOS

04

RESULTADOS

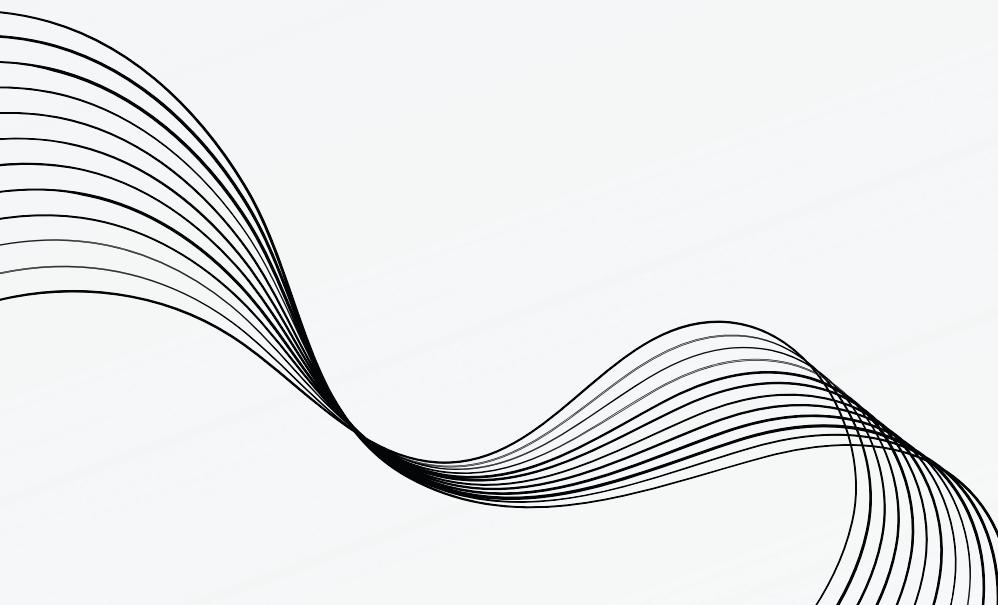
05

CONCLUSIONES Y HALLAZGOS PRINCIPALES

1. DEFINICIÓN Y MOTIVACIÓN DEL ESTUDIO

PROBLEMA A ABORDAR:

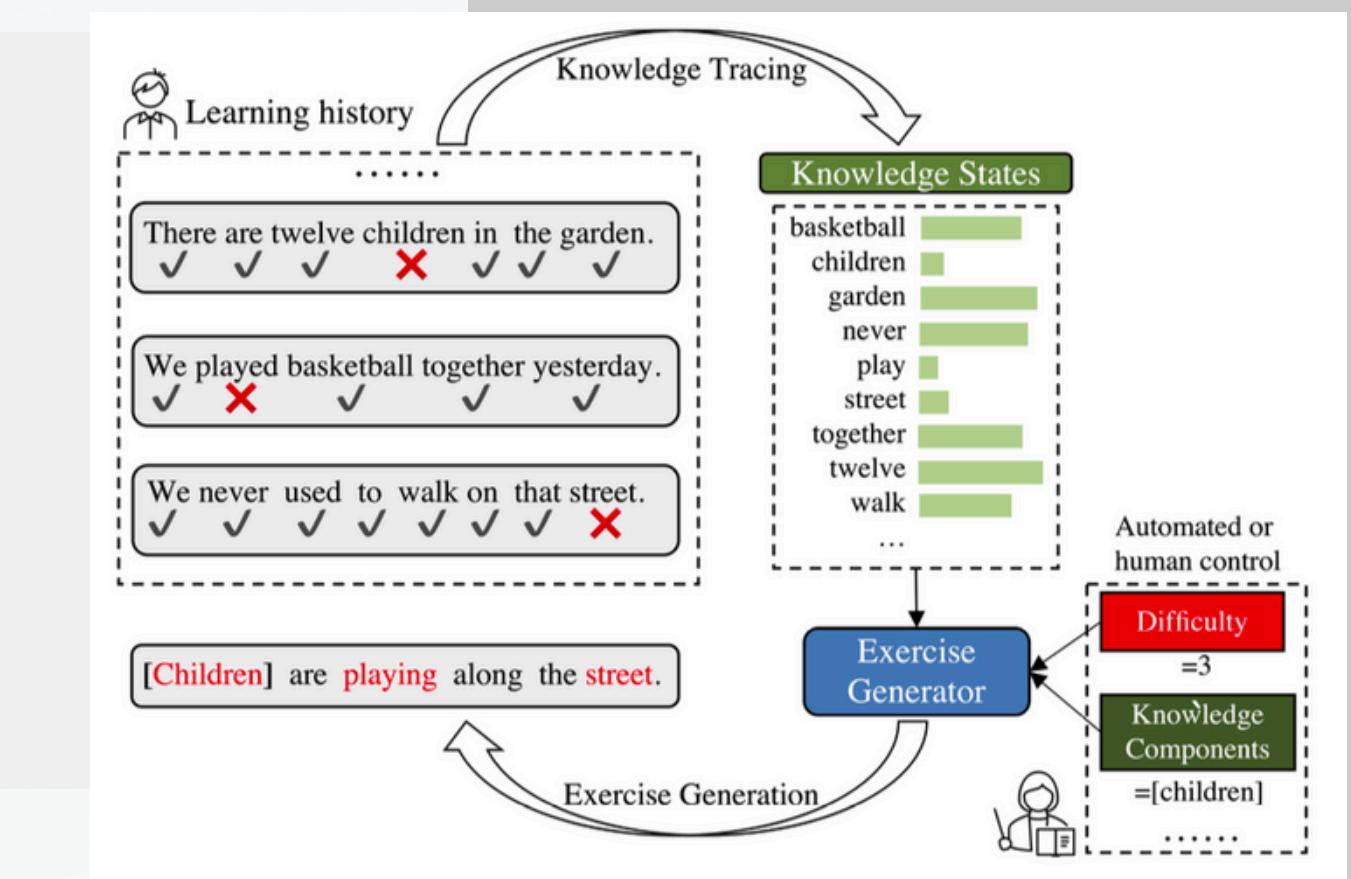
**GENERACIÓN ADAPTATIVA Y PERSONALIZADA DE EJERCICIOS
PARA OPTIMIZAR EL APRENDIZAJE DE IDIOMAS EN LÍNEA**



1. DEFINICIÓN Y MOTIVACIÓN DEL ESTUDIO



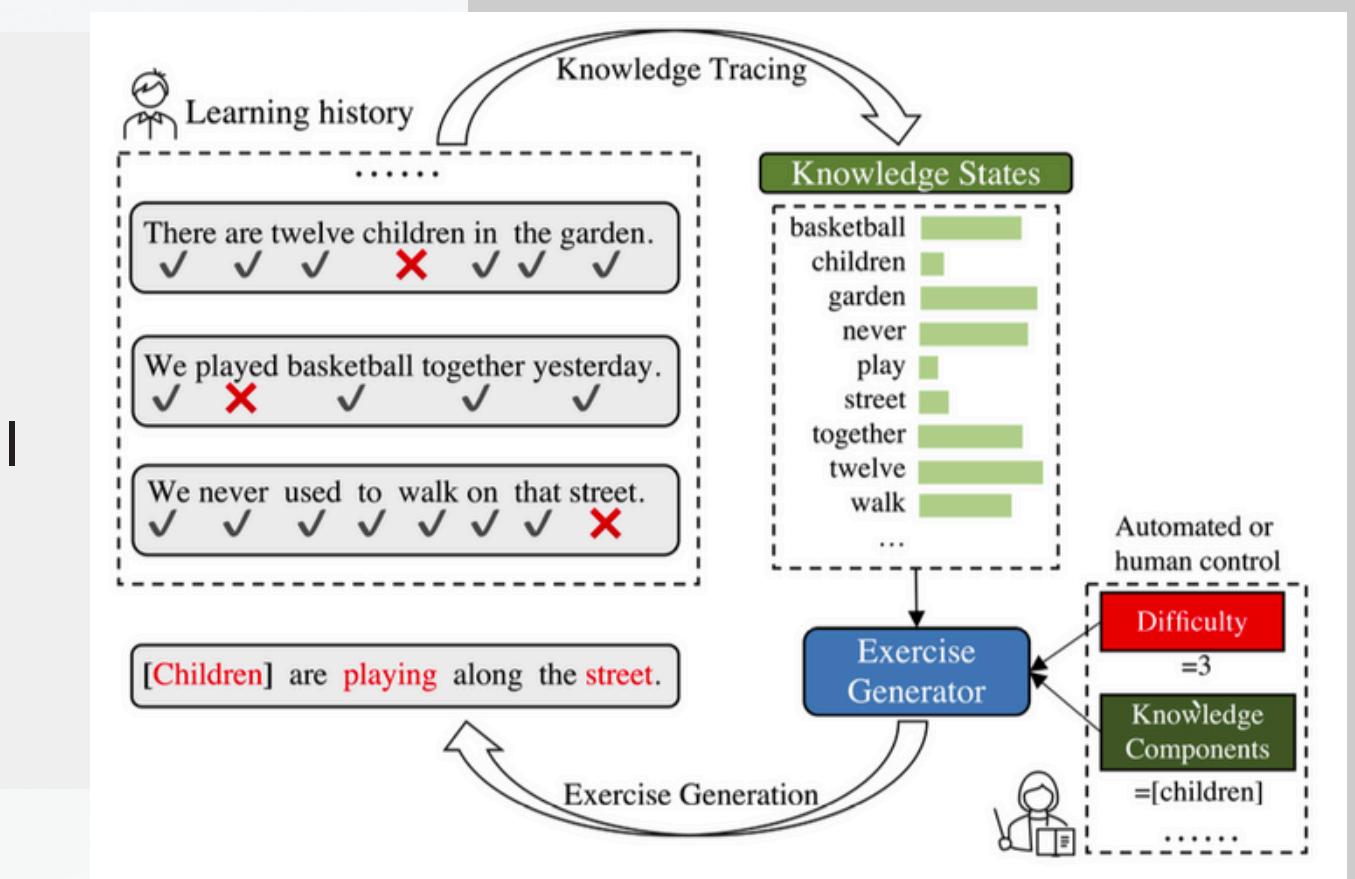
- Mejorar el aprendizaje de idiomas mediante la personalización y adaptación de ejercicios.
- Personalización mejora el rendimiento y reduce el abandono, pero es laborioso manualmente.
- Objetivo: automatizar la creación de ejercicios adaptados usando modelos de trazado de conocimiento.



1. DEFINICIÓN Y MOTIVACIÓN DEL ESTUDIO



- Las tecnologías de aprendizaje adaptativo han mostrado mejores resultados y mayor satisfacción de instructores.
- Es especialmente relevante en el crecimiento del aprendizaje en línea.
- Se requiere de soluciones escalables para personalizar la experiencia educativa.



TRABAJOS RELACIONADOS



ESTUDIOS SOBRE
TECNOLOGÍAS DE
APRENDIZAJE
ADAPTATIVO



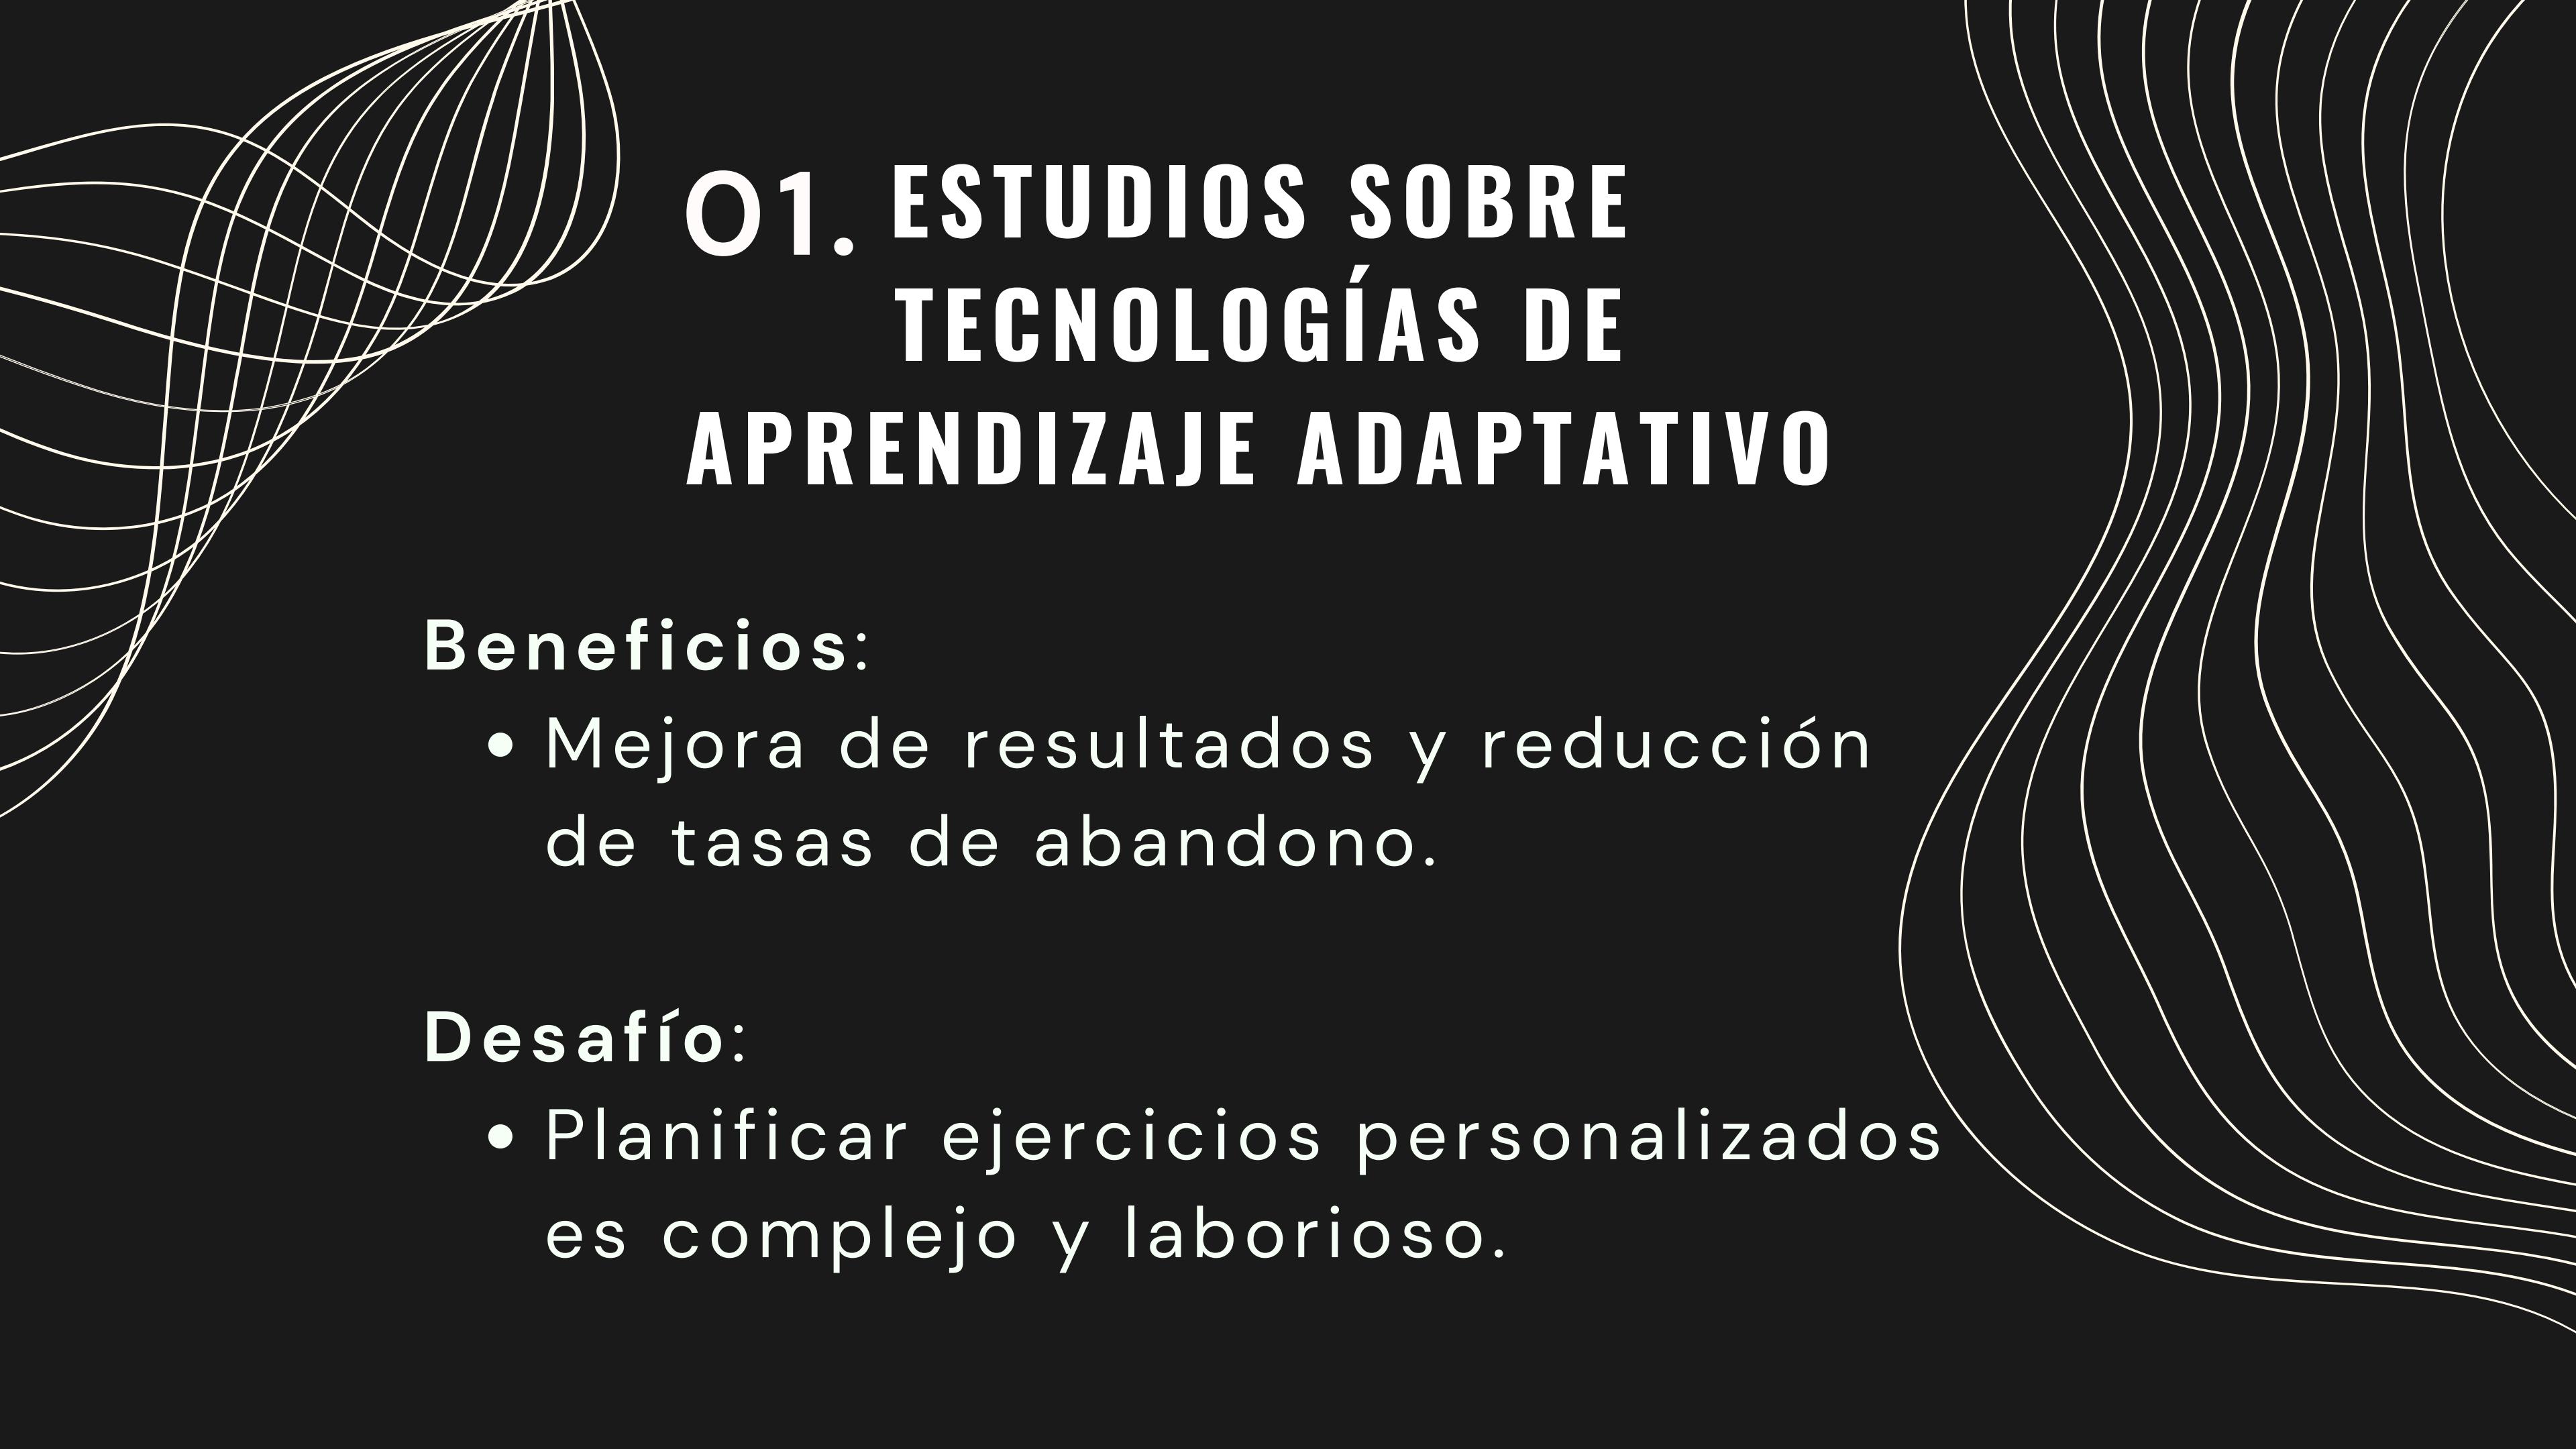
GENERACIÓN
AUTOMÁTICA DE
EJERCICIOS
BASADA EN TEXTO



MODELOS DE
TRAZADO DE
CONOCIMIENTO



GENERACIÓN DE
EJERCICIOS CON
CONTROL SOBRE
LA DIFICULTAD Y
EL DOMINIO DEL
CONOCIMIENTO:



01. ESTUDIOS SOBRE TECNOLOGÍAS DE APRENDIZAJE ADAPTATIVO

Beneficios:

- Mejora de resultados y reducción de tasas de abandono.

Desafío:

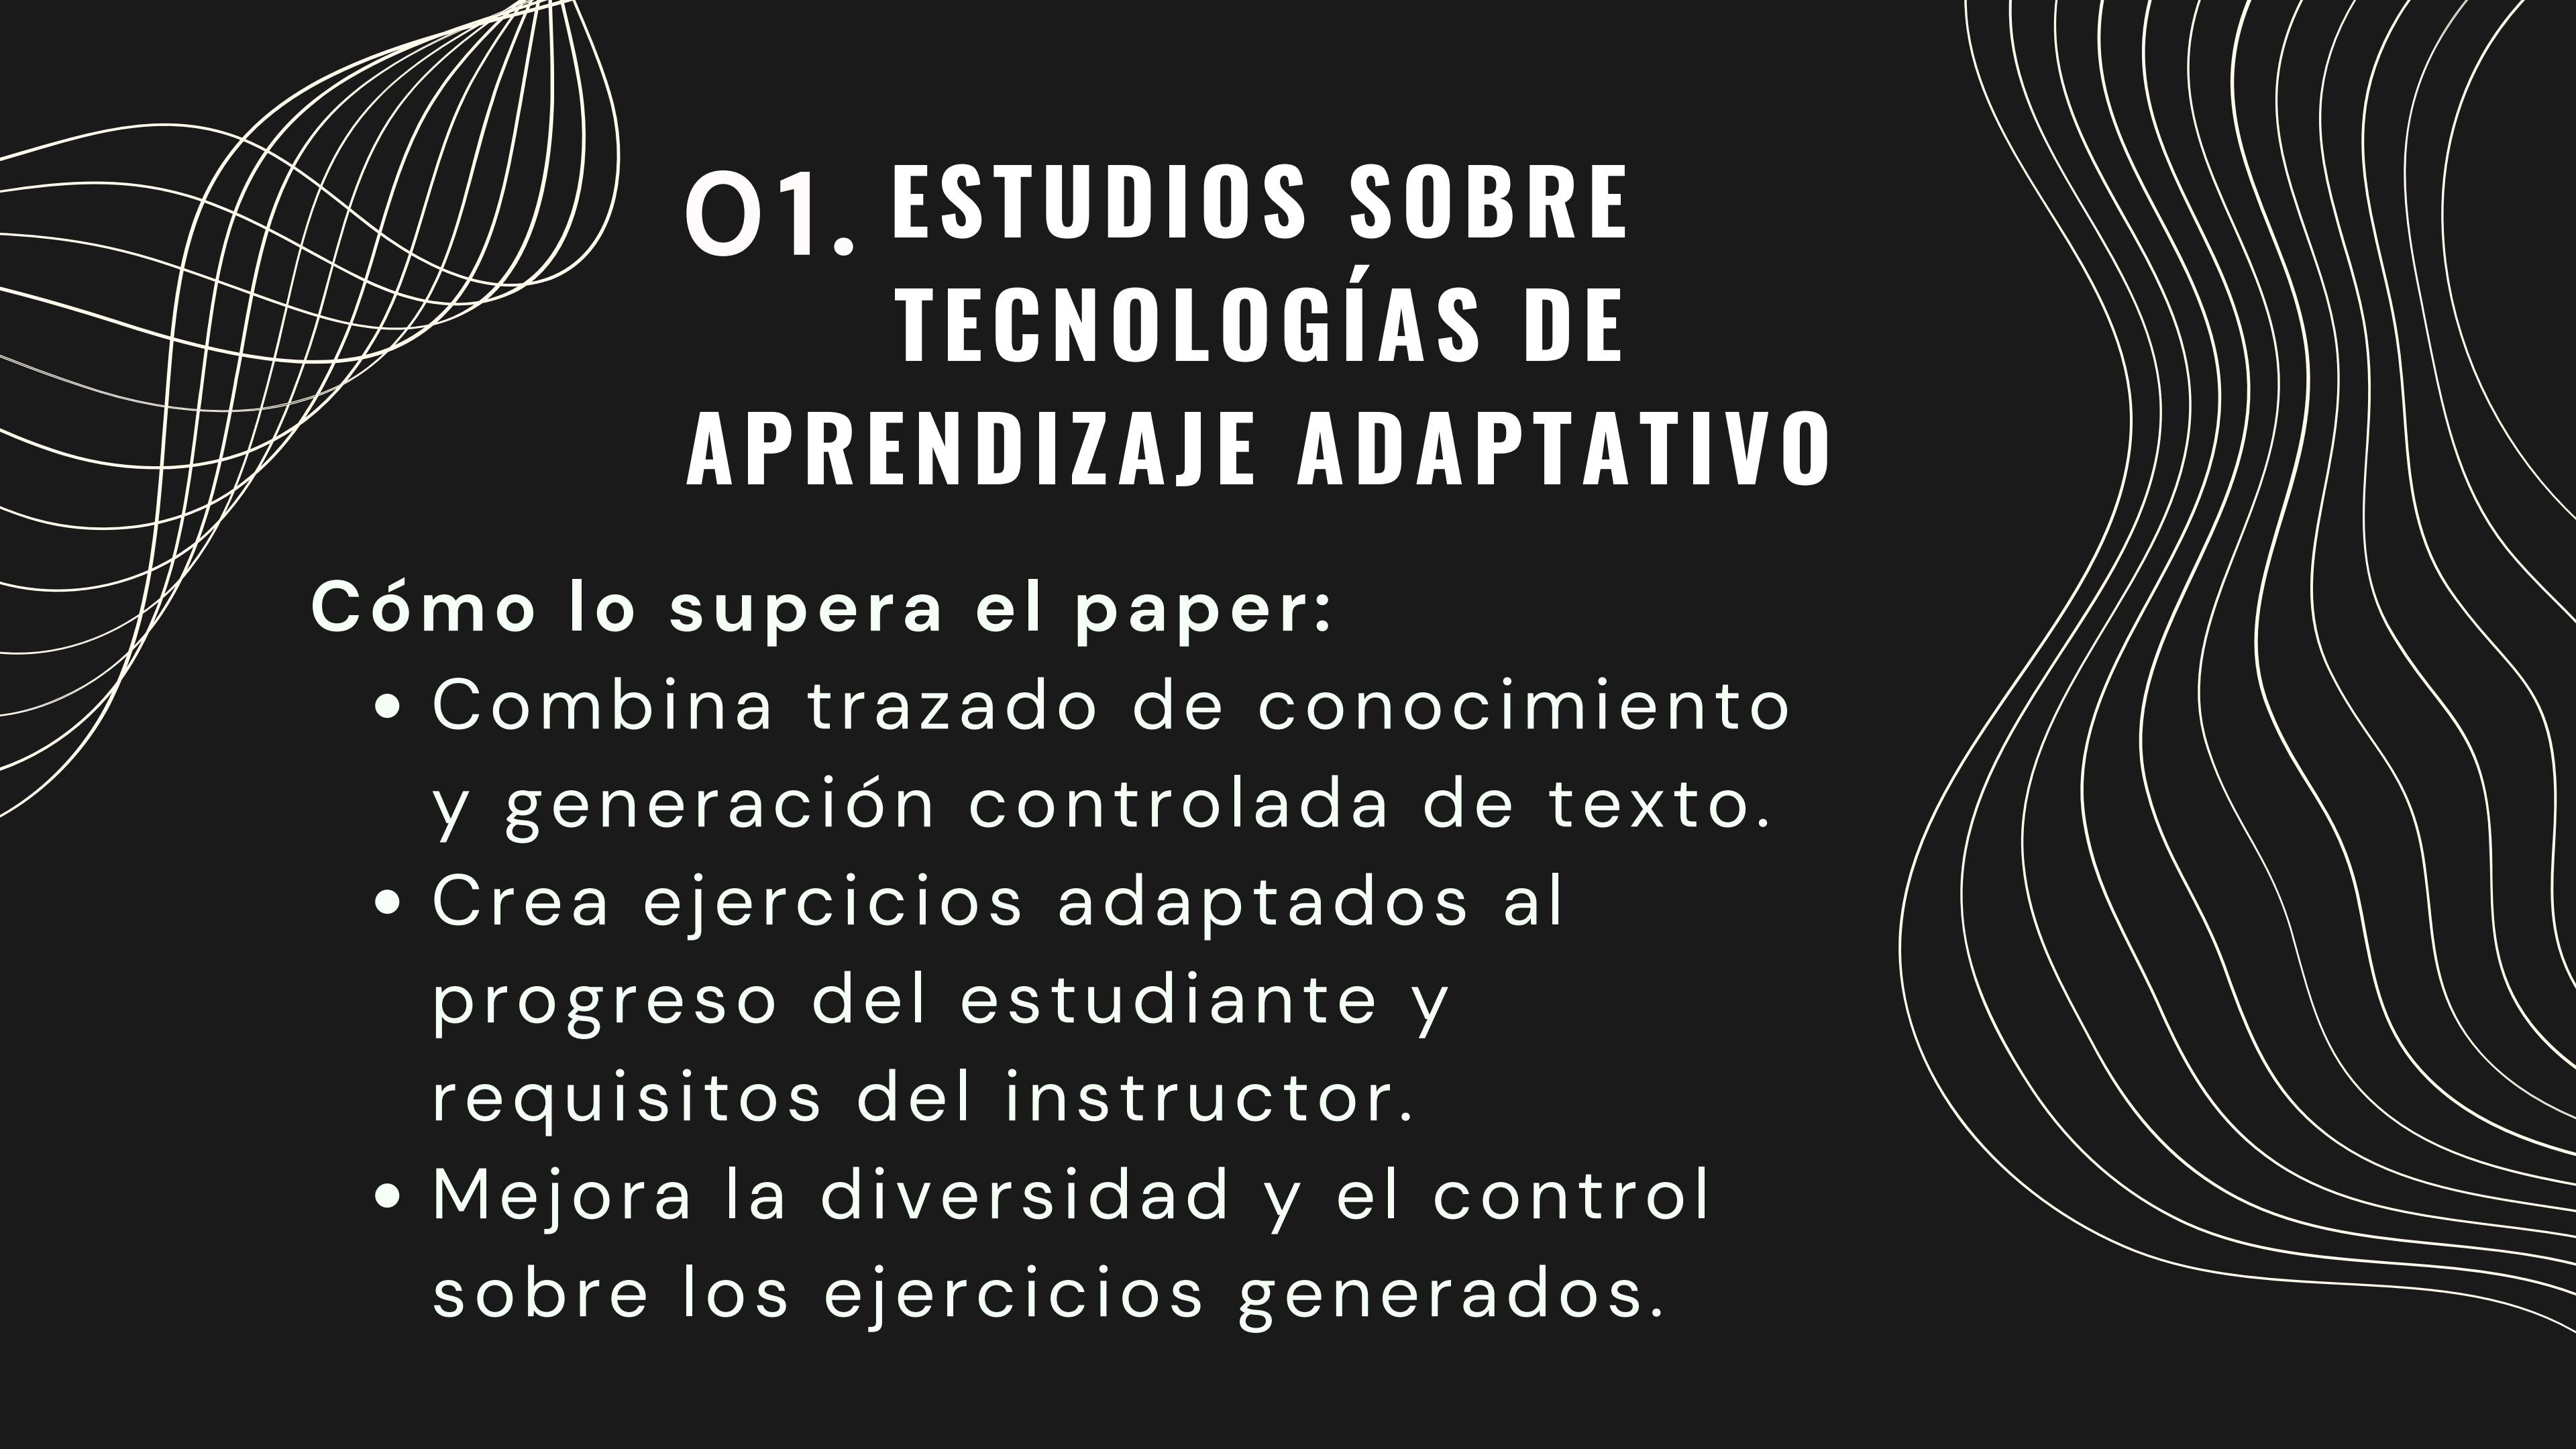
- Planificar ejercicios personalizados es complejo y laborioso.



O1. ESTUDIOS SOBRE TECNOLOGÍAS DE APRENDIZAJE ADAPTATIVO

Limitación:

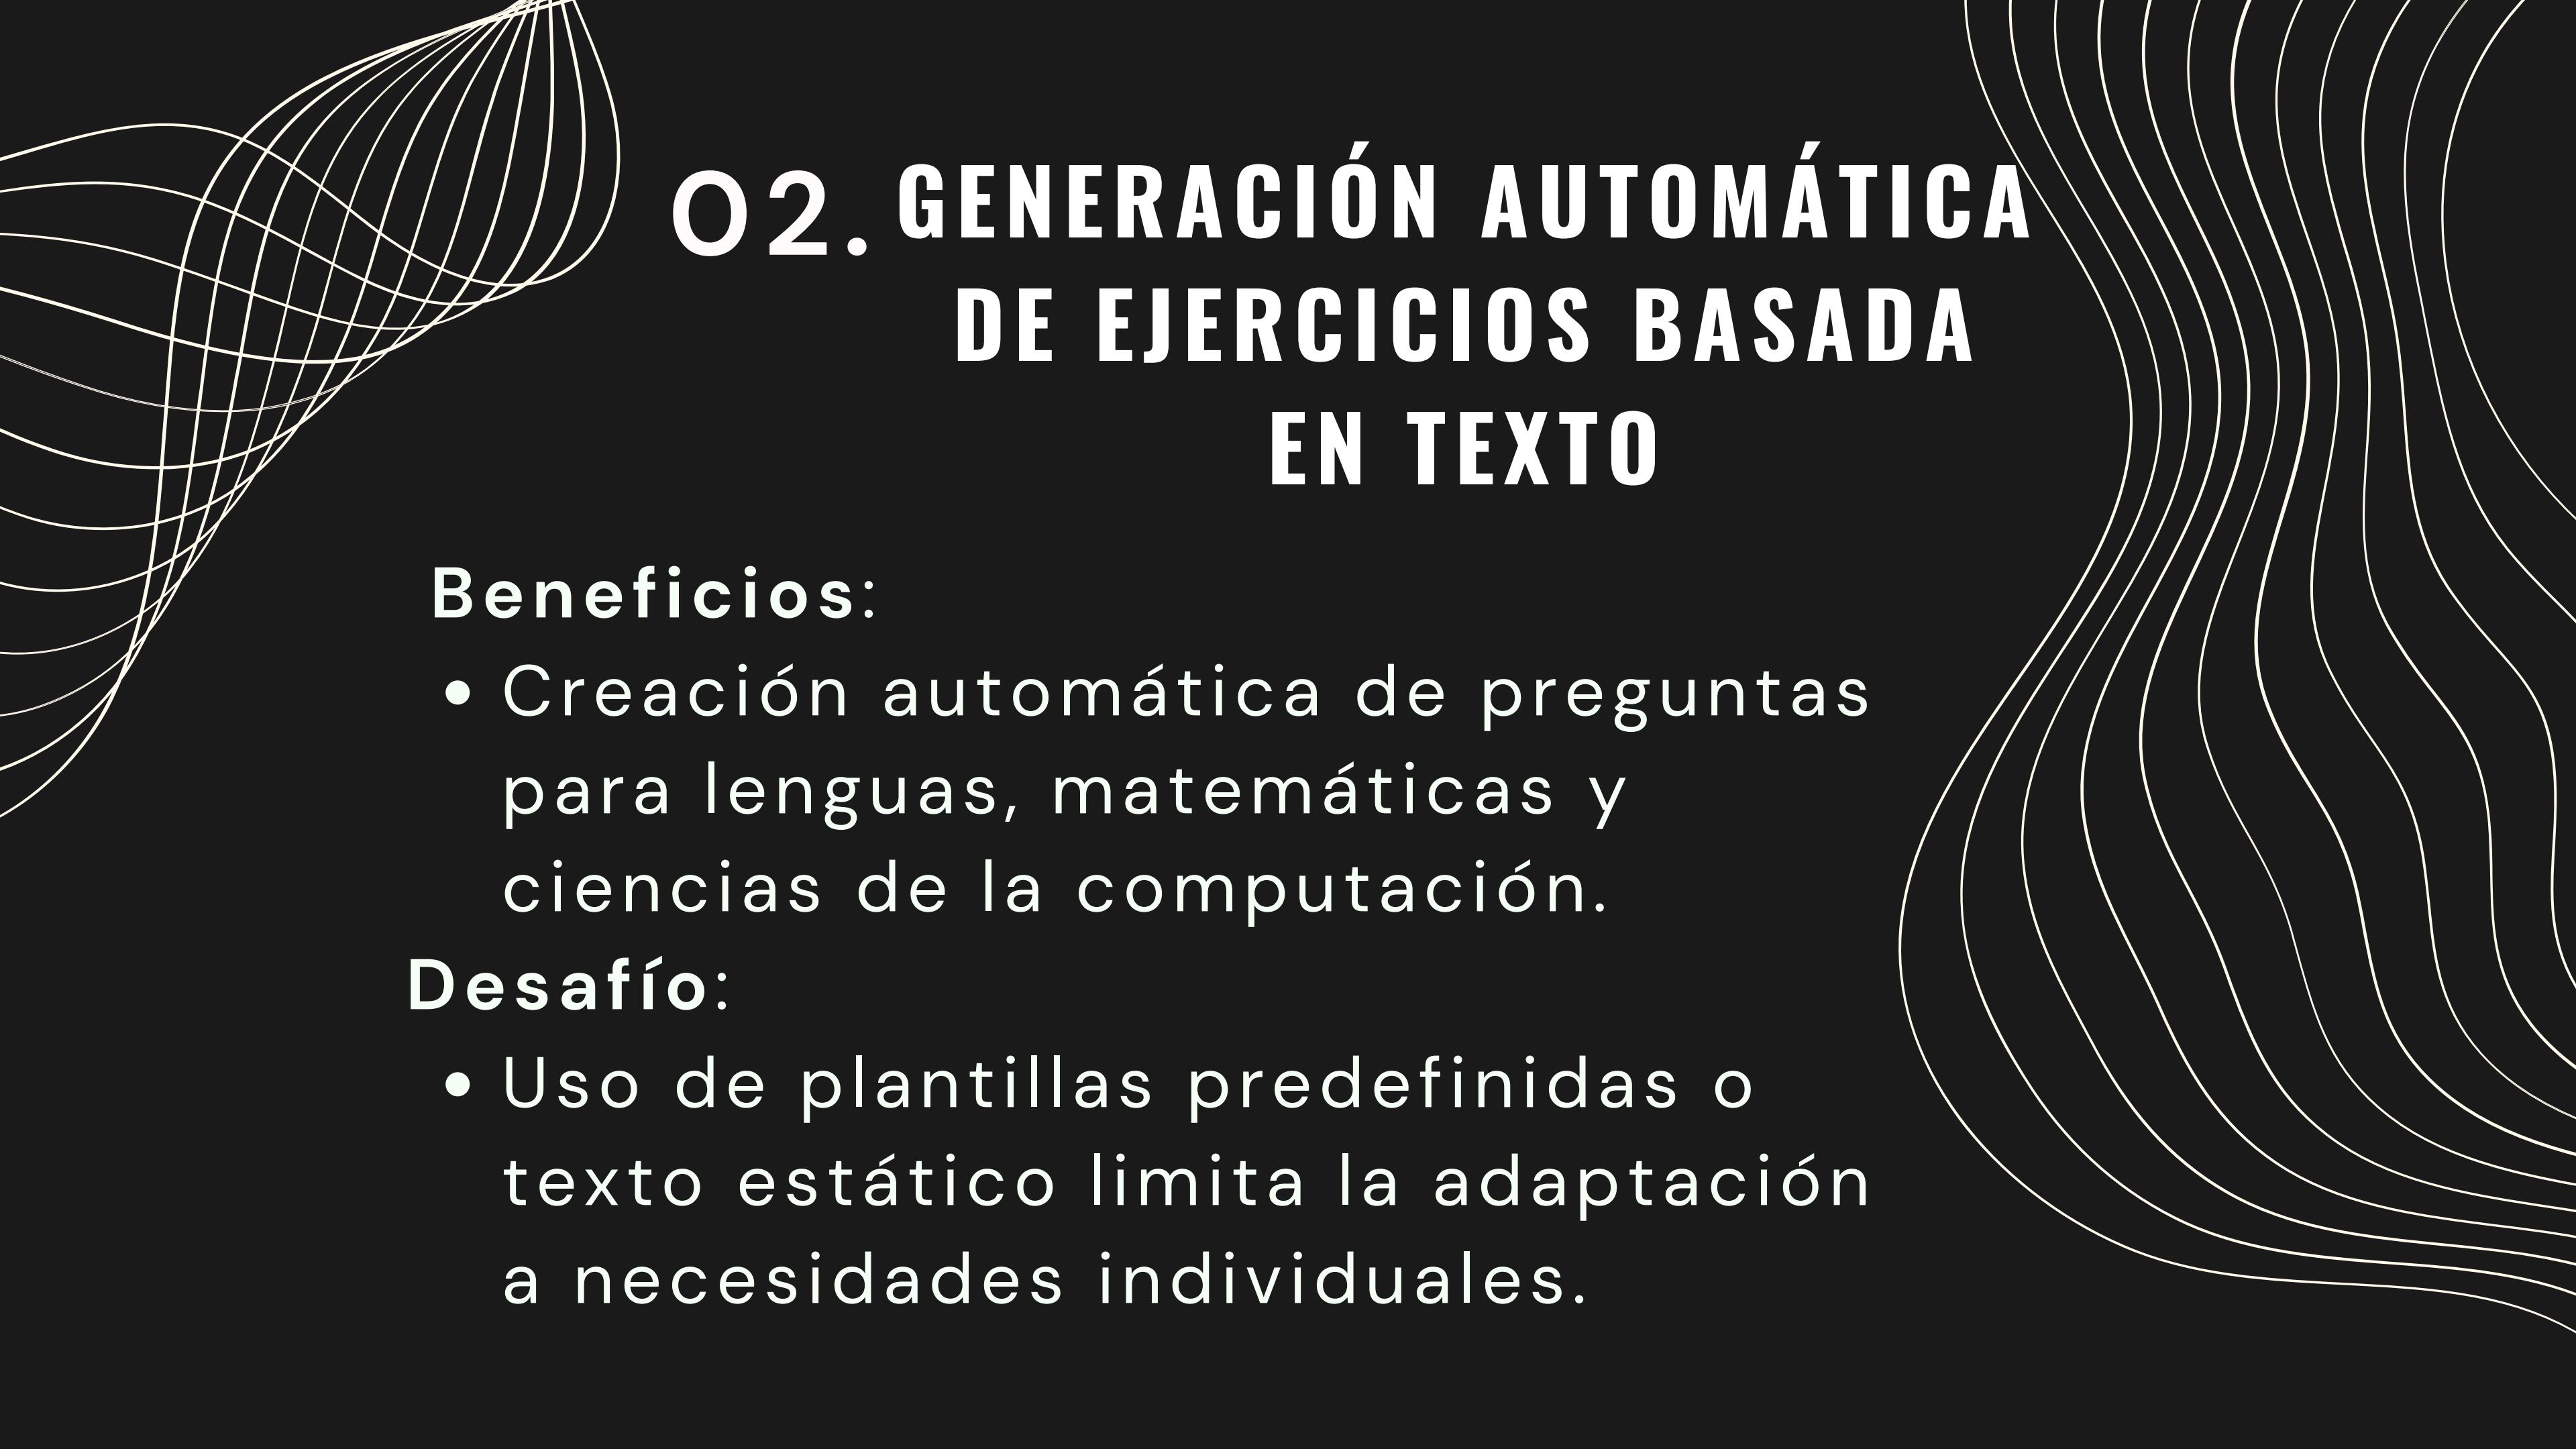
- Dependencia de plantillas predefinidas y fuentes específicas.
- Cobertura limitada del conocimiento y control deficiente sobre la dificultad.



01. ESTUDIOS SOBRE TECNOLOGÍAS DE APRENDIZAJE ADAPTATIVO

Cómo lo supera el paper:

- Combina trazado de conocimiento y generación controlada de texto.
- Crea ejercicios adaptados al progreso del estudiante y requisitos del instructor.
- Mejora la diversidad y el control sobre los ejercicios generados.



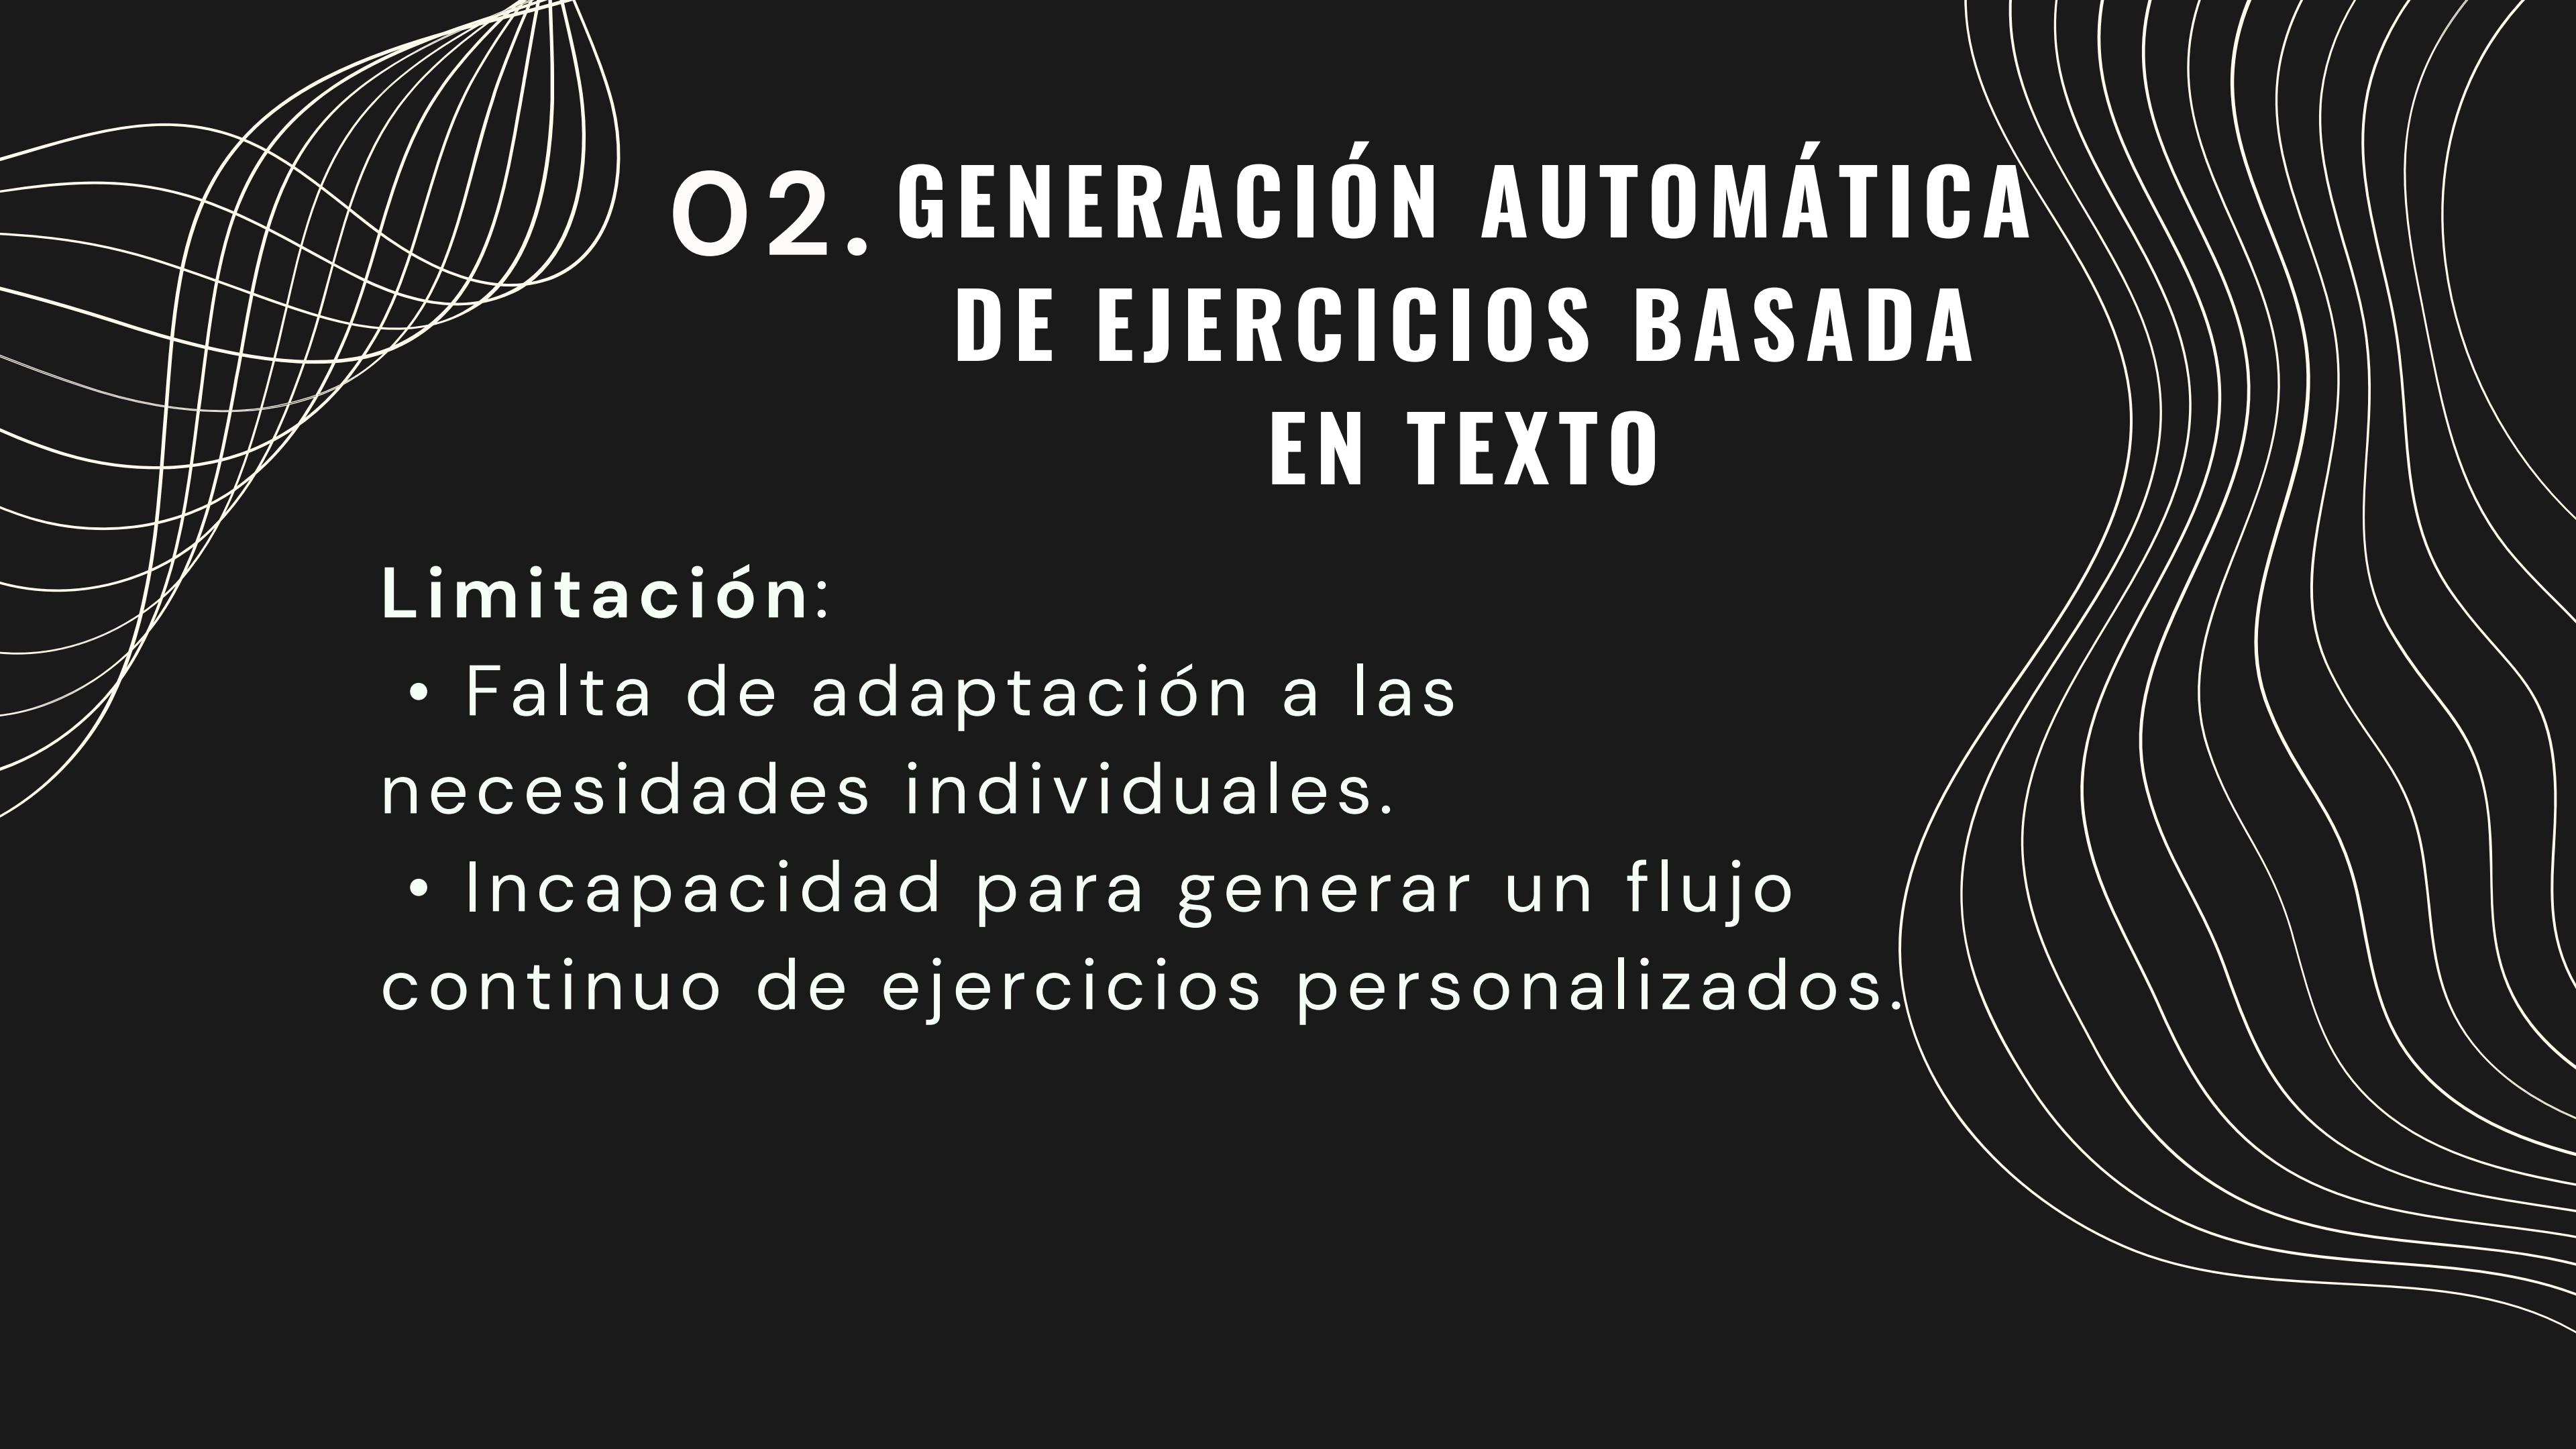
02. GENERACIÓN AUTOMÁTICA DE EJERCICIOS BASADA EN TEXTO

Beneficios:

- Creación automática de preguntas para lenguas, matemáticas y ciencias de la computación.

Desafío:

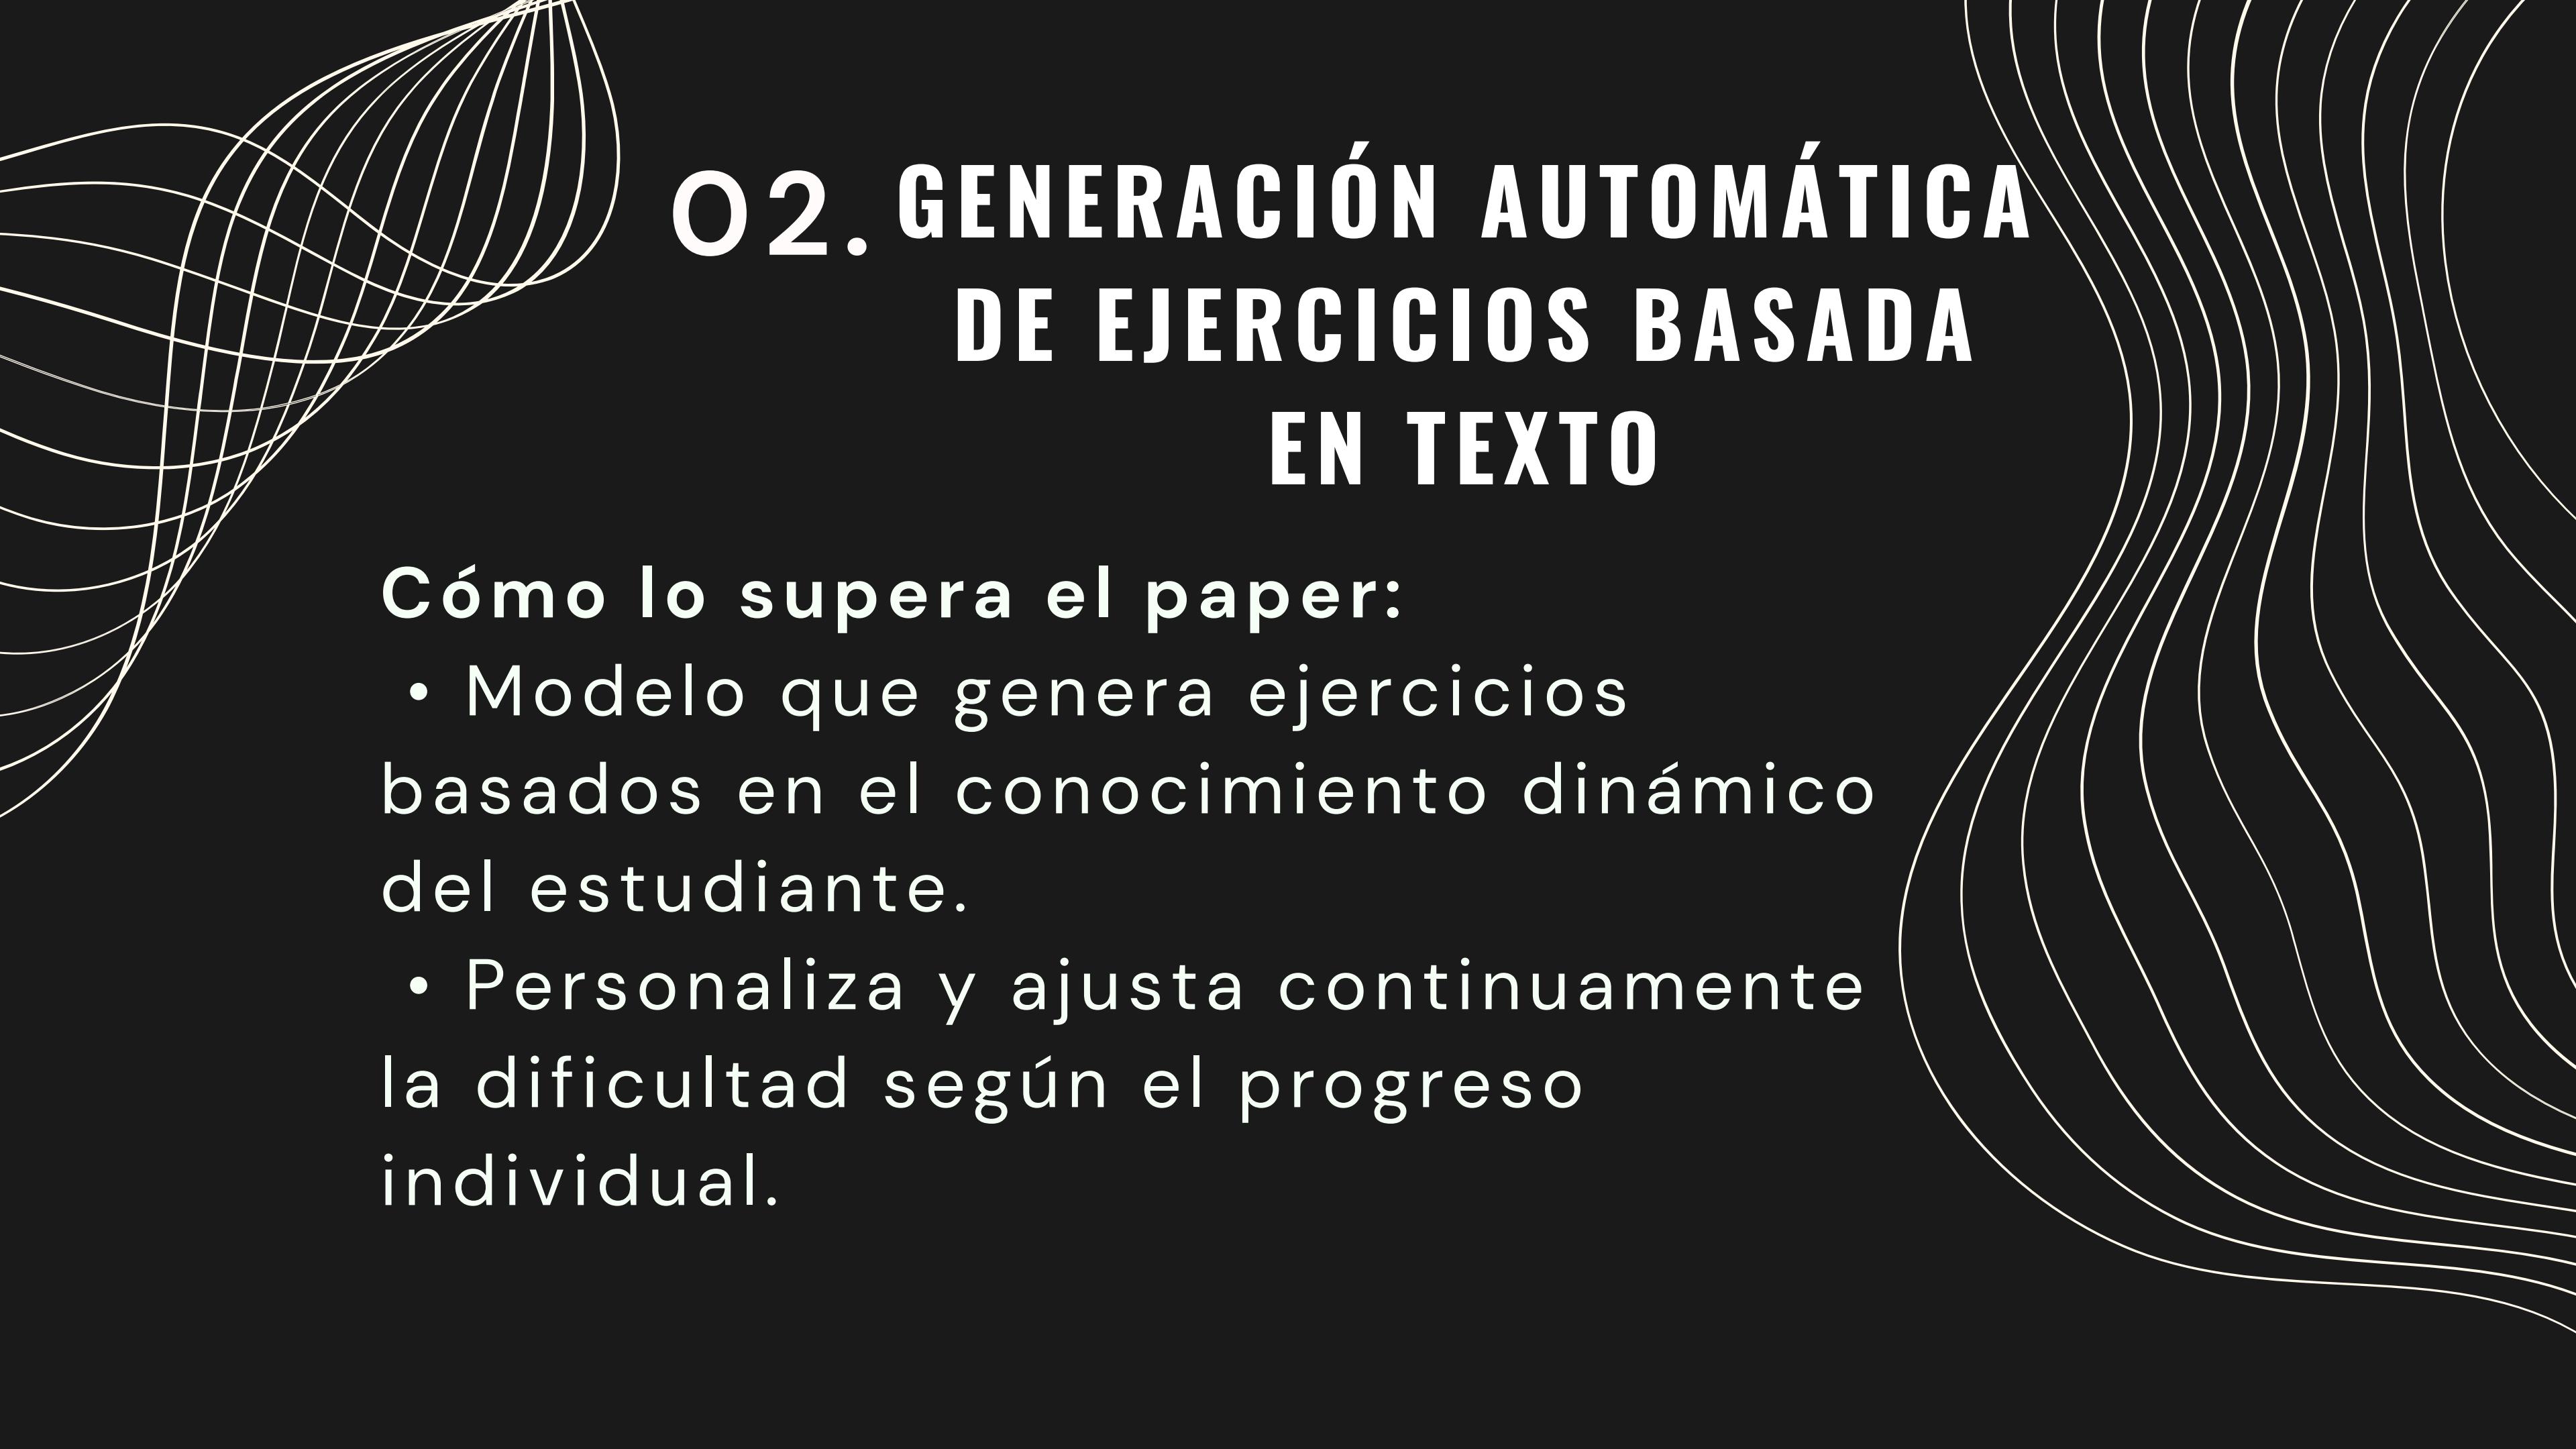
- Uso de plantillas predefinidas o texto estático limita la adaptación a necesidades individuales.



02. GENERACIÓN AUTOMÁTICA DE EJERCICIOS BASADA EN TEXTO

Limitación:

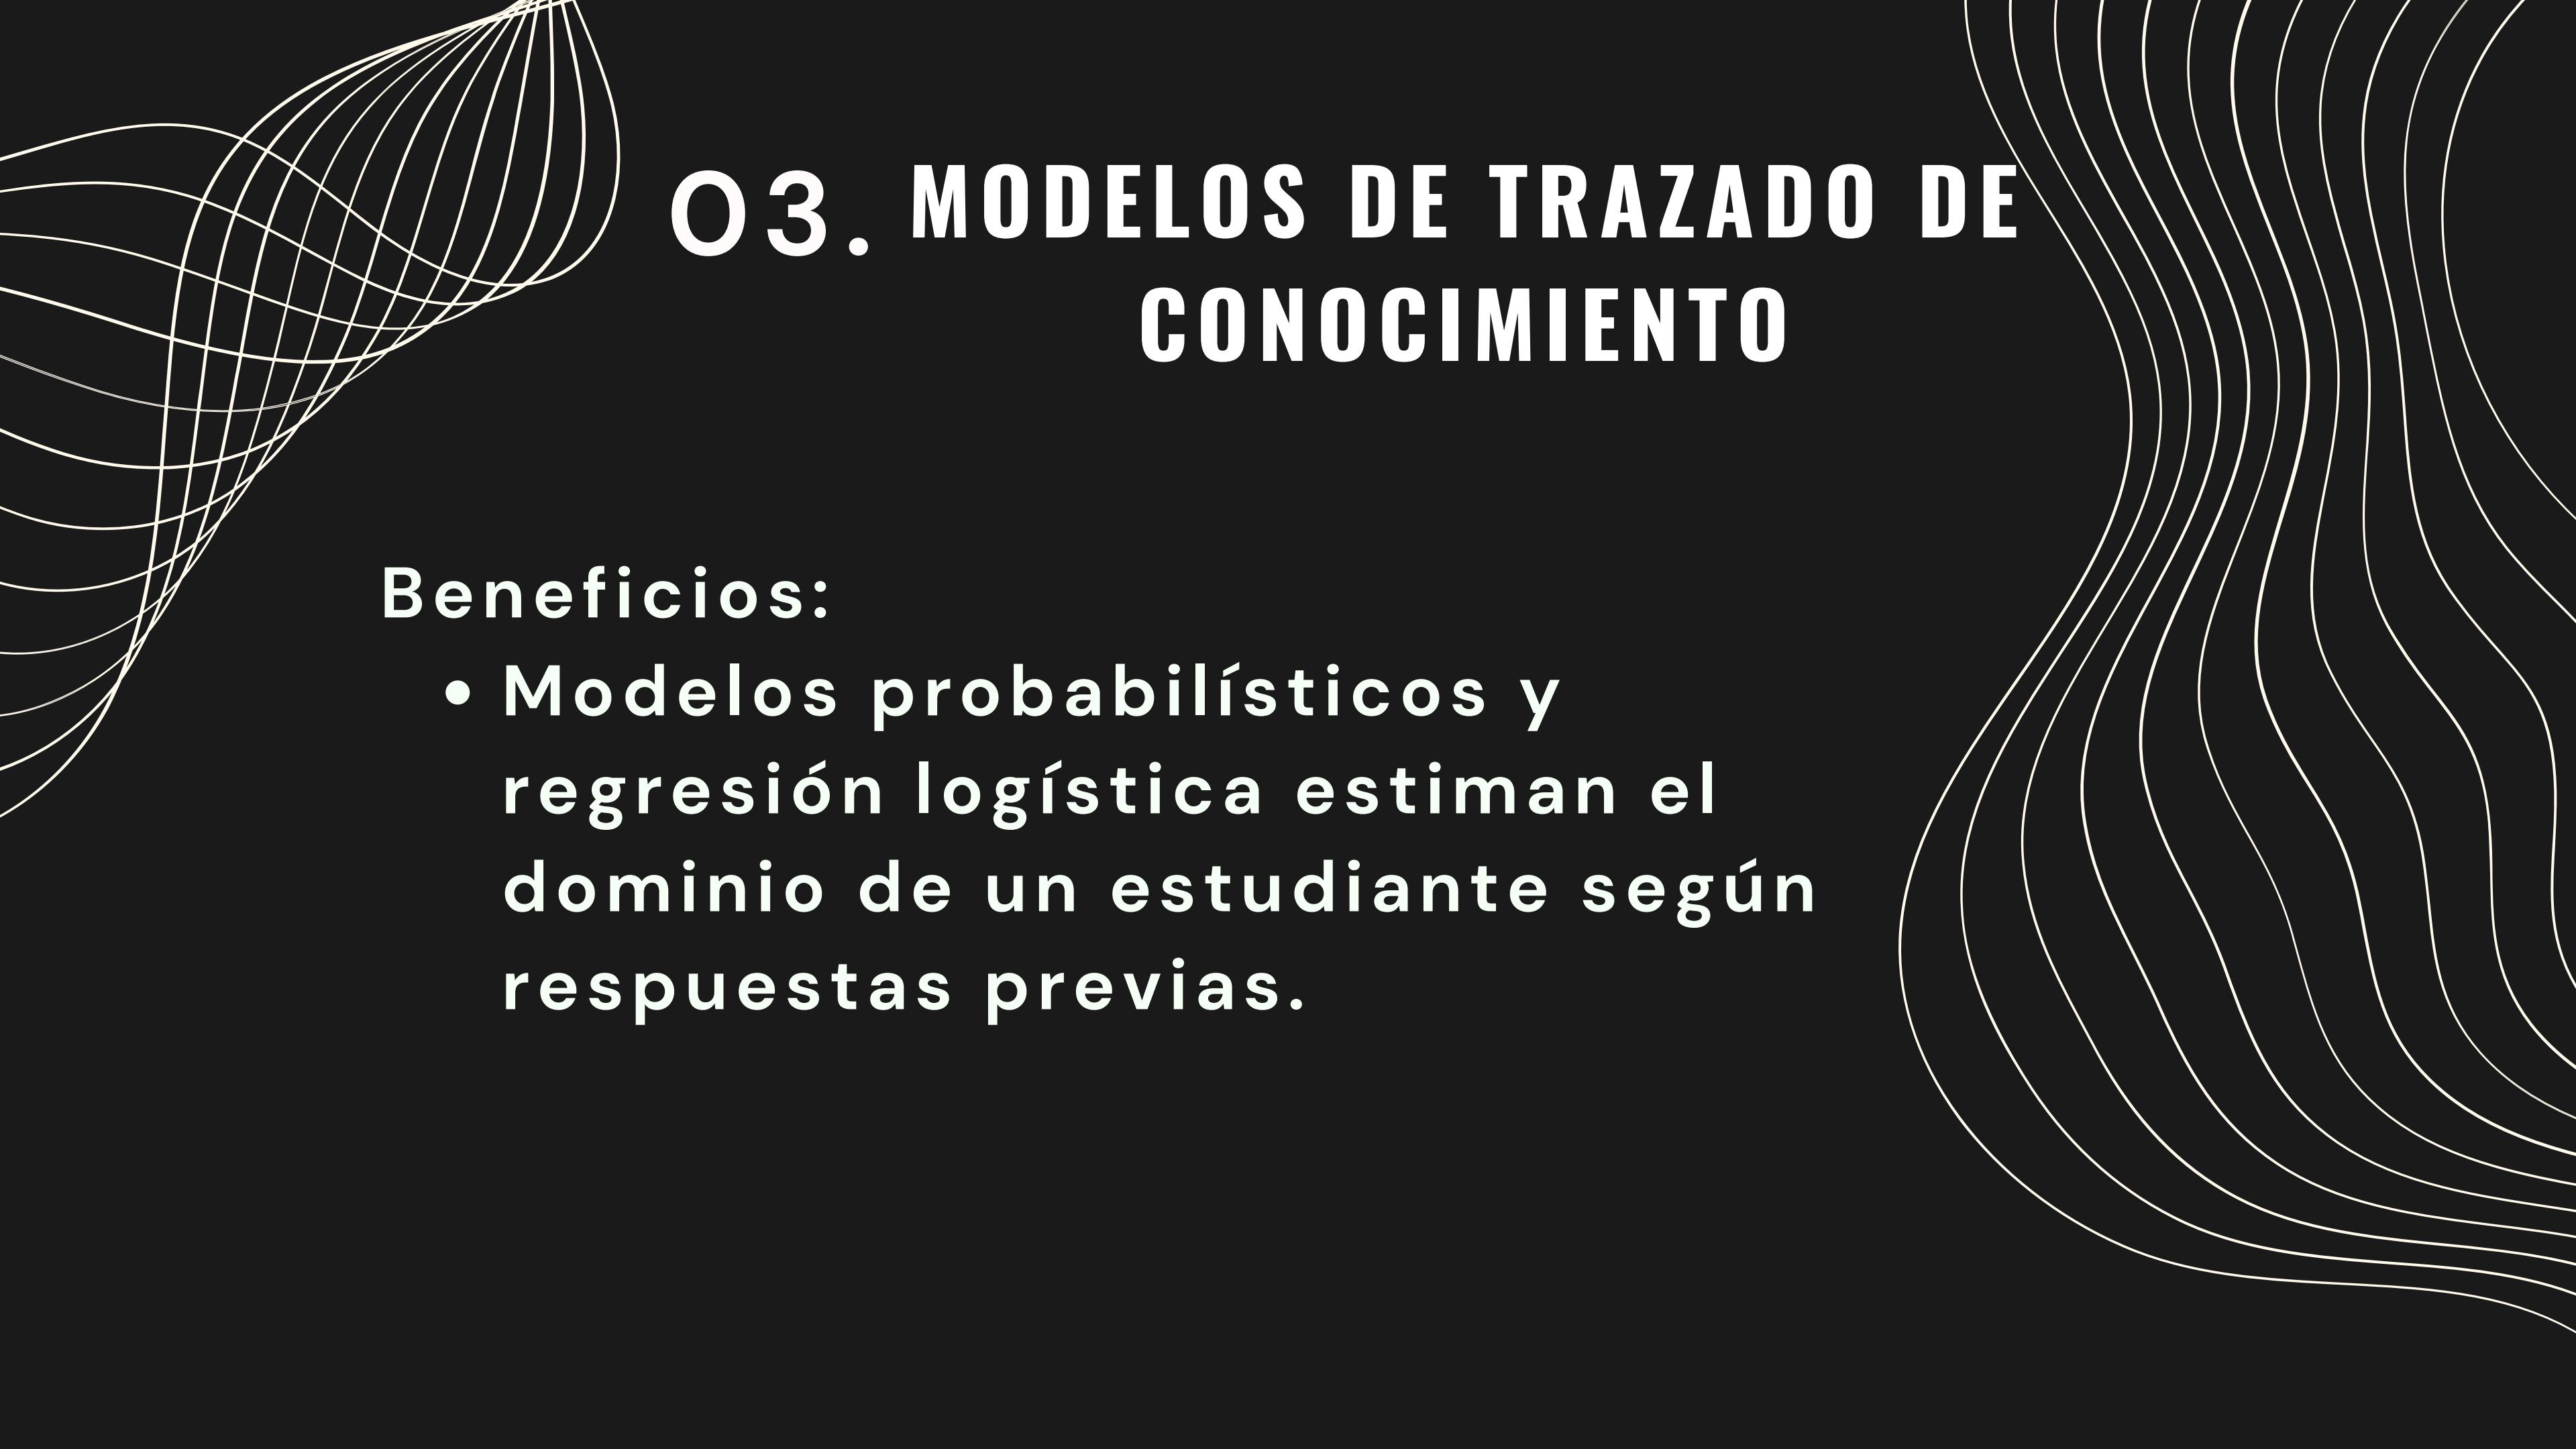
- Falta de adaptación a las necesidades individuales.
- Incapacidad para generar un flujo continuo de ejercicios personalizados.



02. GENERACIÓN AUTOMÁTICA DE EJERCICIOS BASADA EN TEXTO

Cómo lo supera el paper:

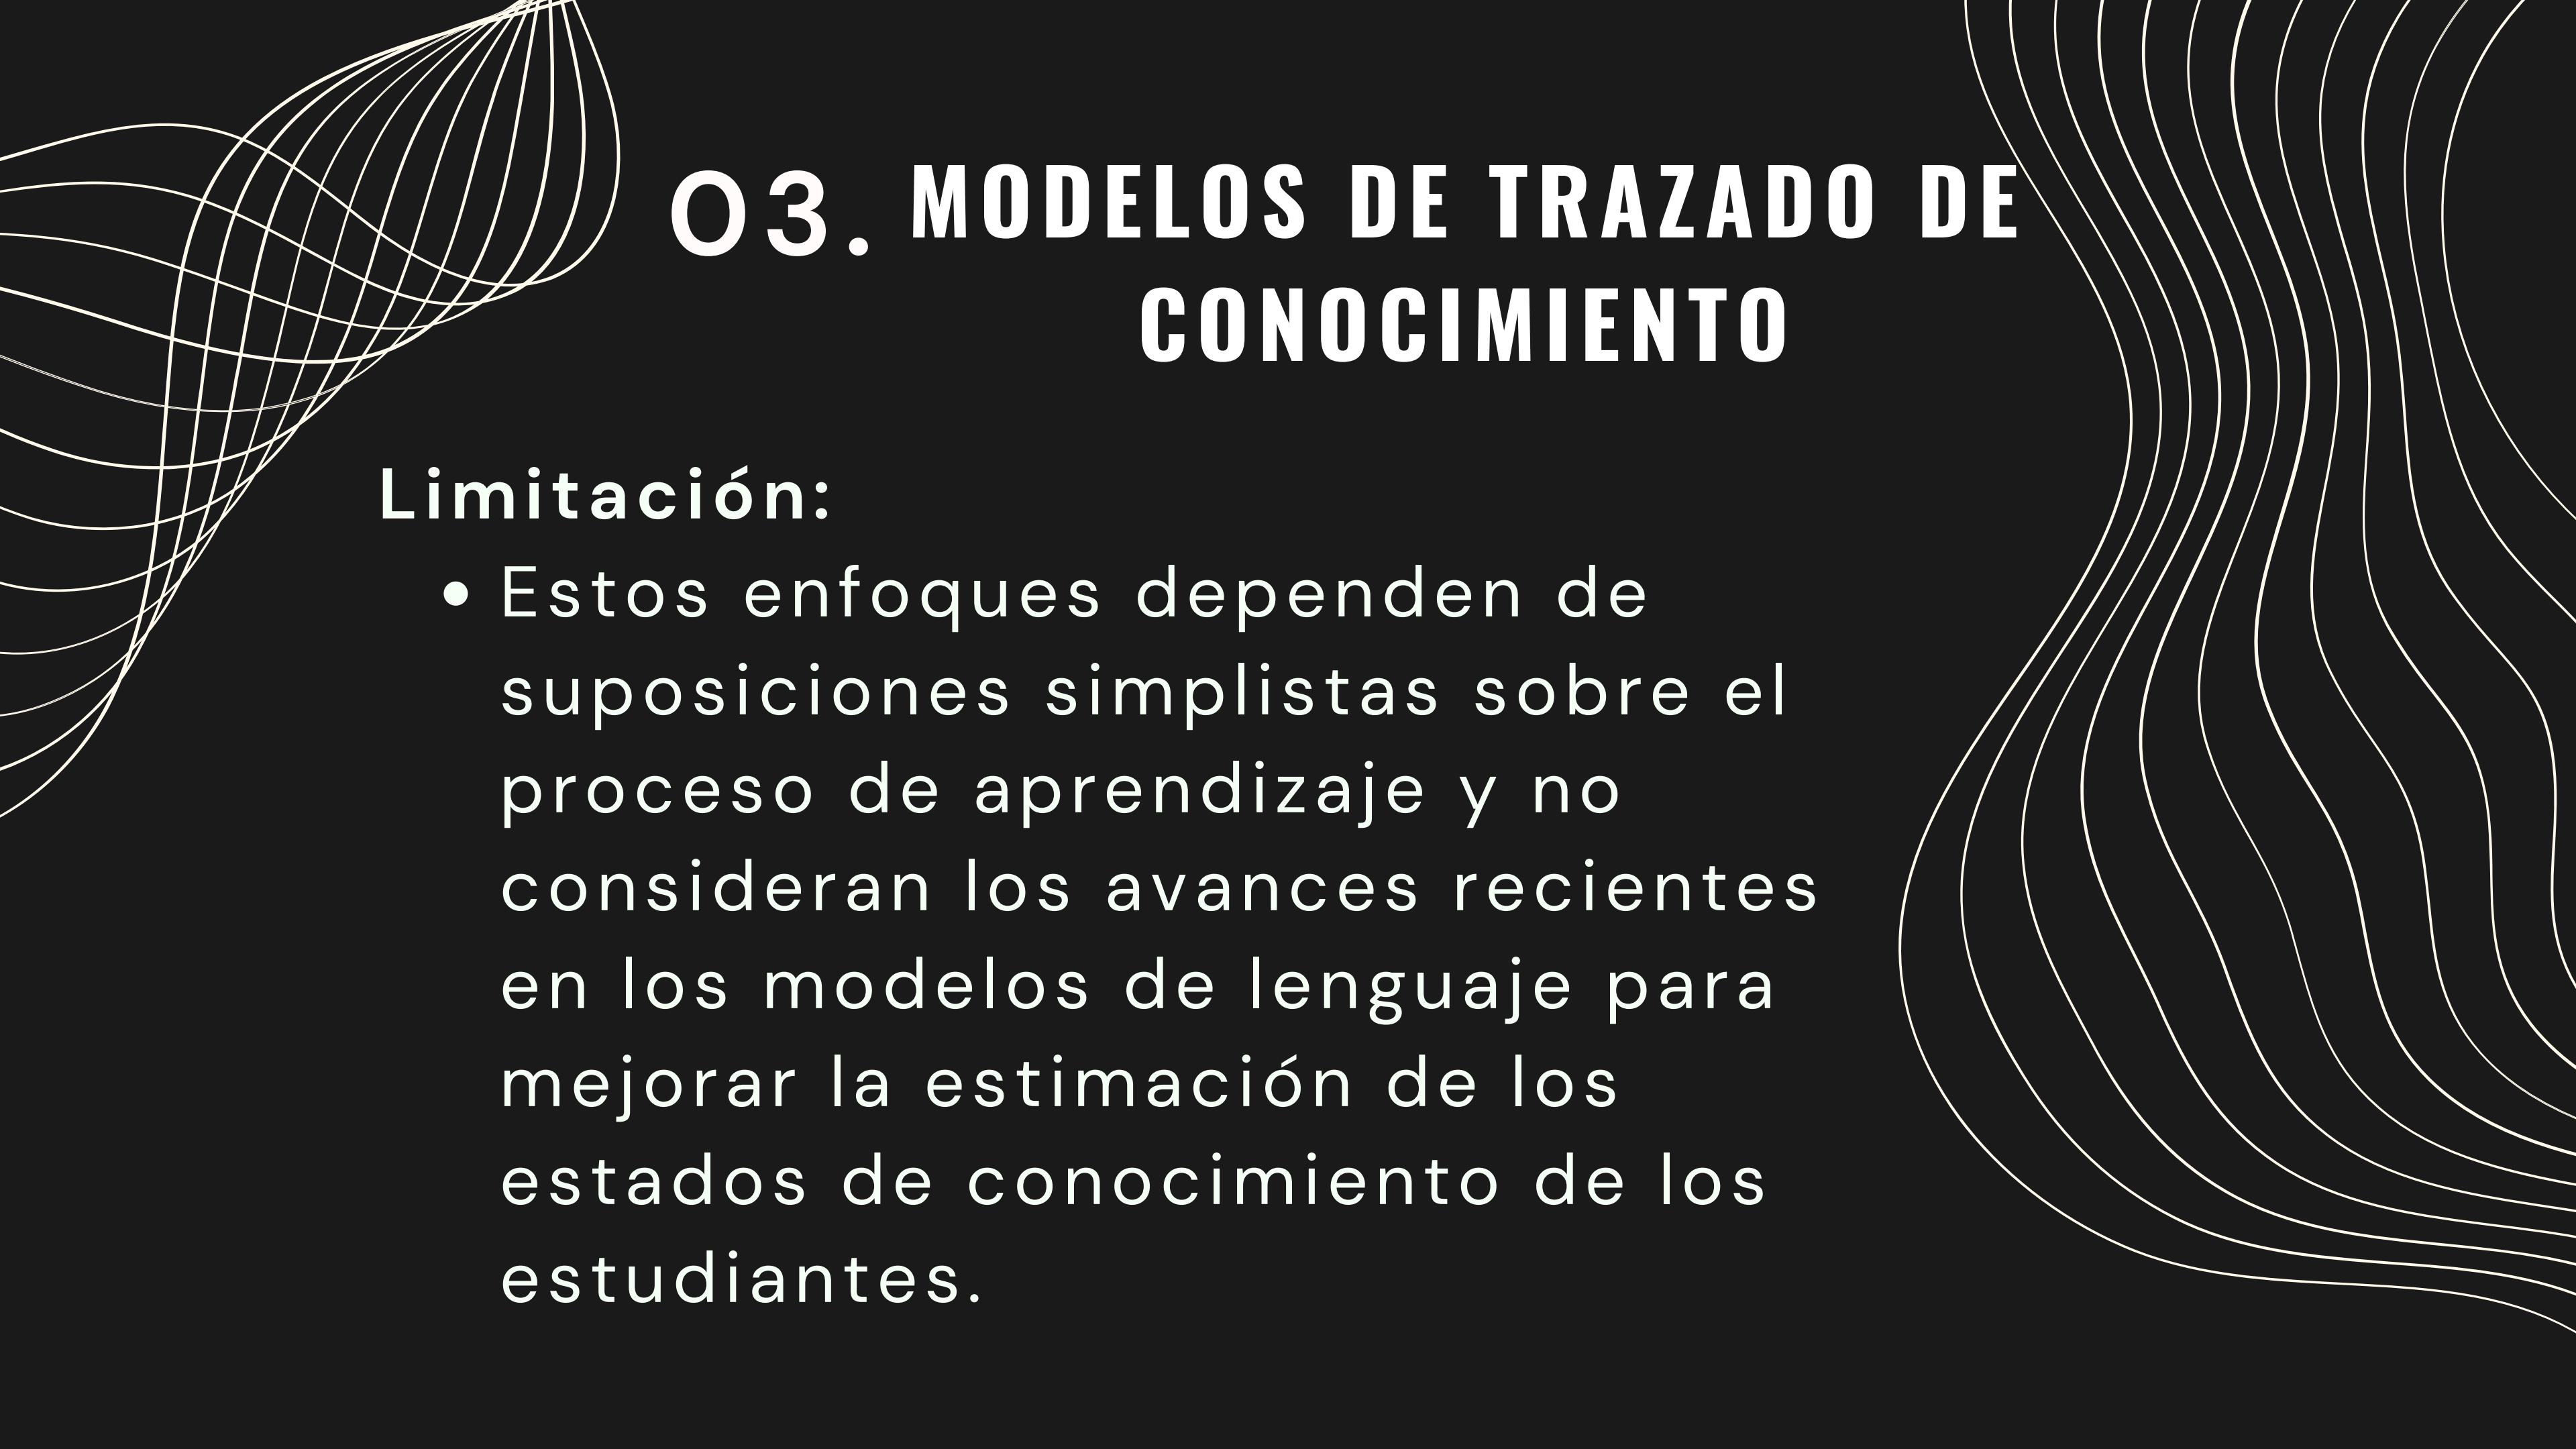
- Modelo que genera ejercicios basados en el conocimiento dinámico del estudiante.
- Personaliza y ajusta continuamente la dificultad según el progreso individual.



03. MODELOS DE TRAZADO DE CONOCIMIENTO

Beneficios:

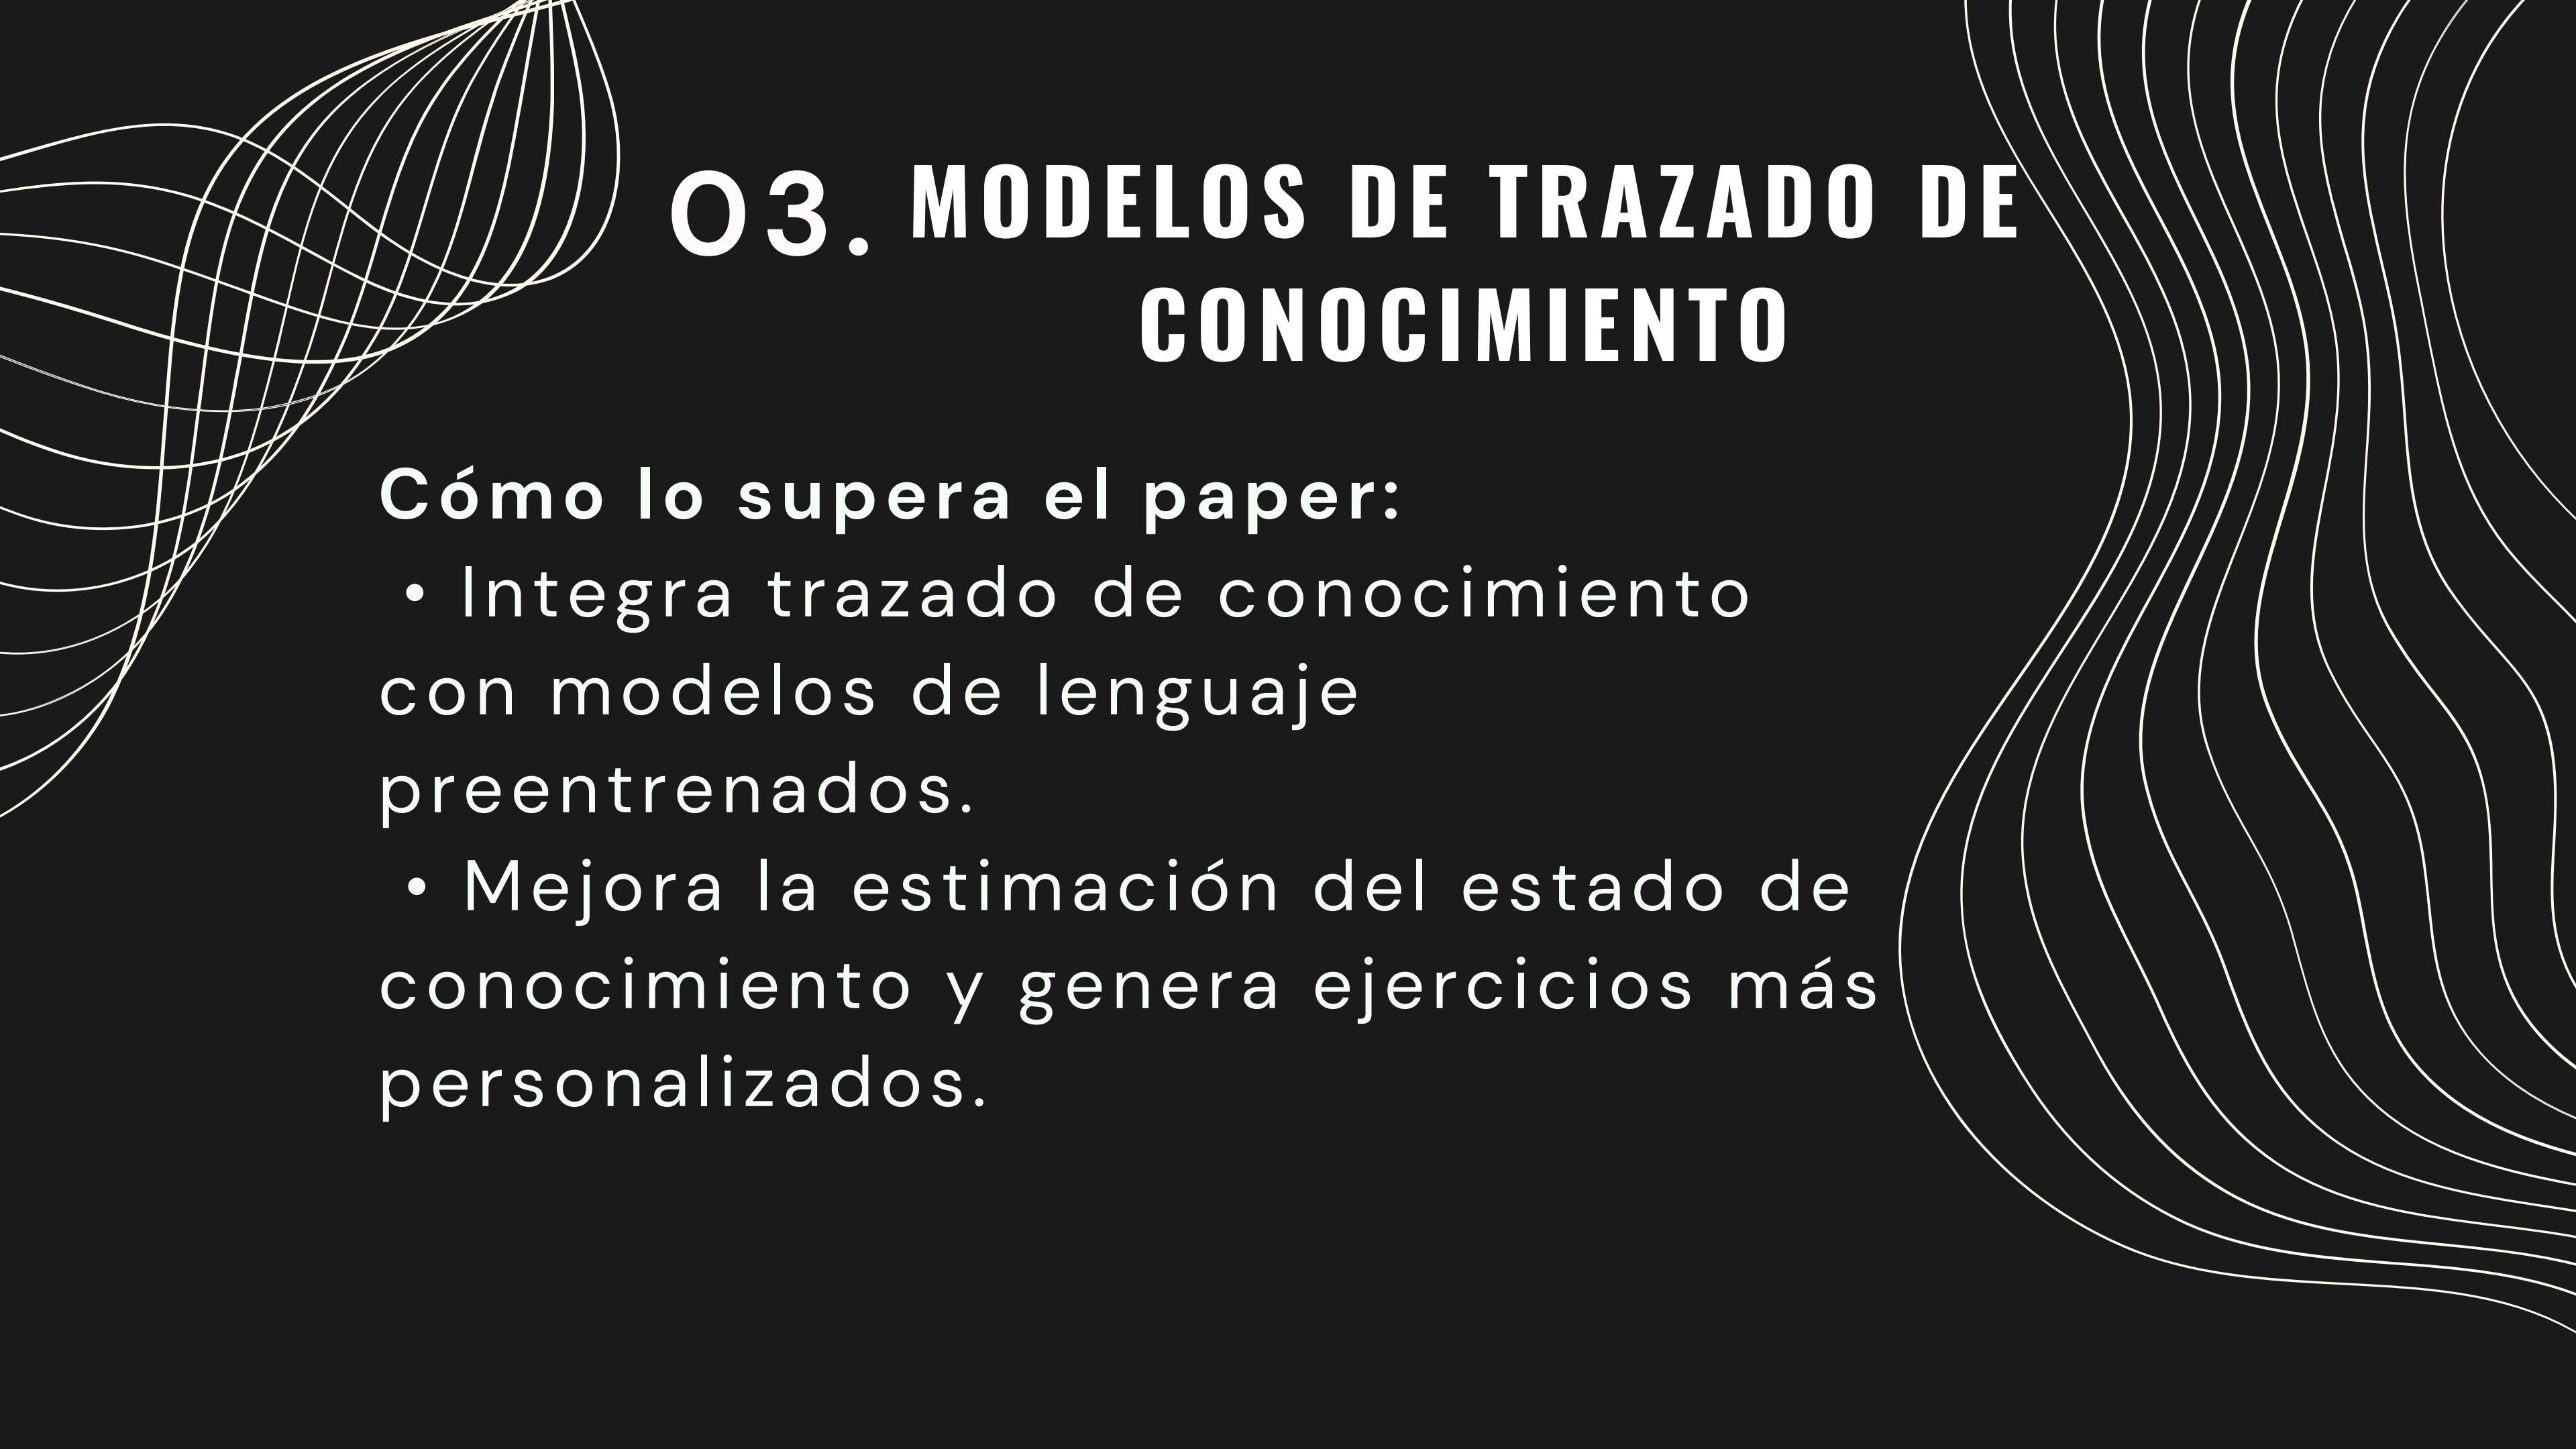
- Modelos probabilísticos y regresión logística estiman el dominio de un estudiante según respuestas previas.



O3. MODELOS DE TRAZADO DE CONOCIMIENTO

Limitación:

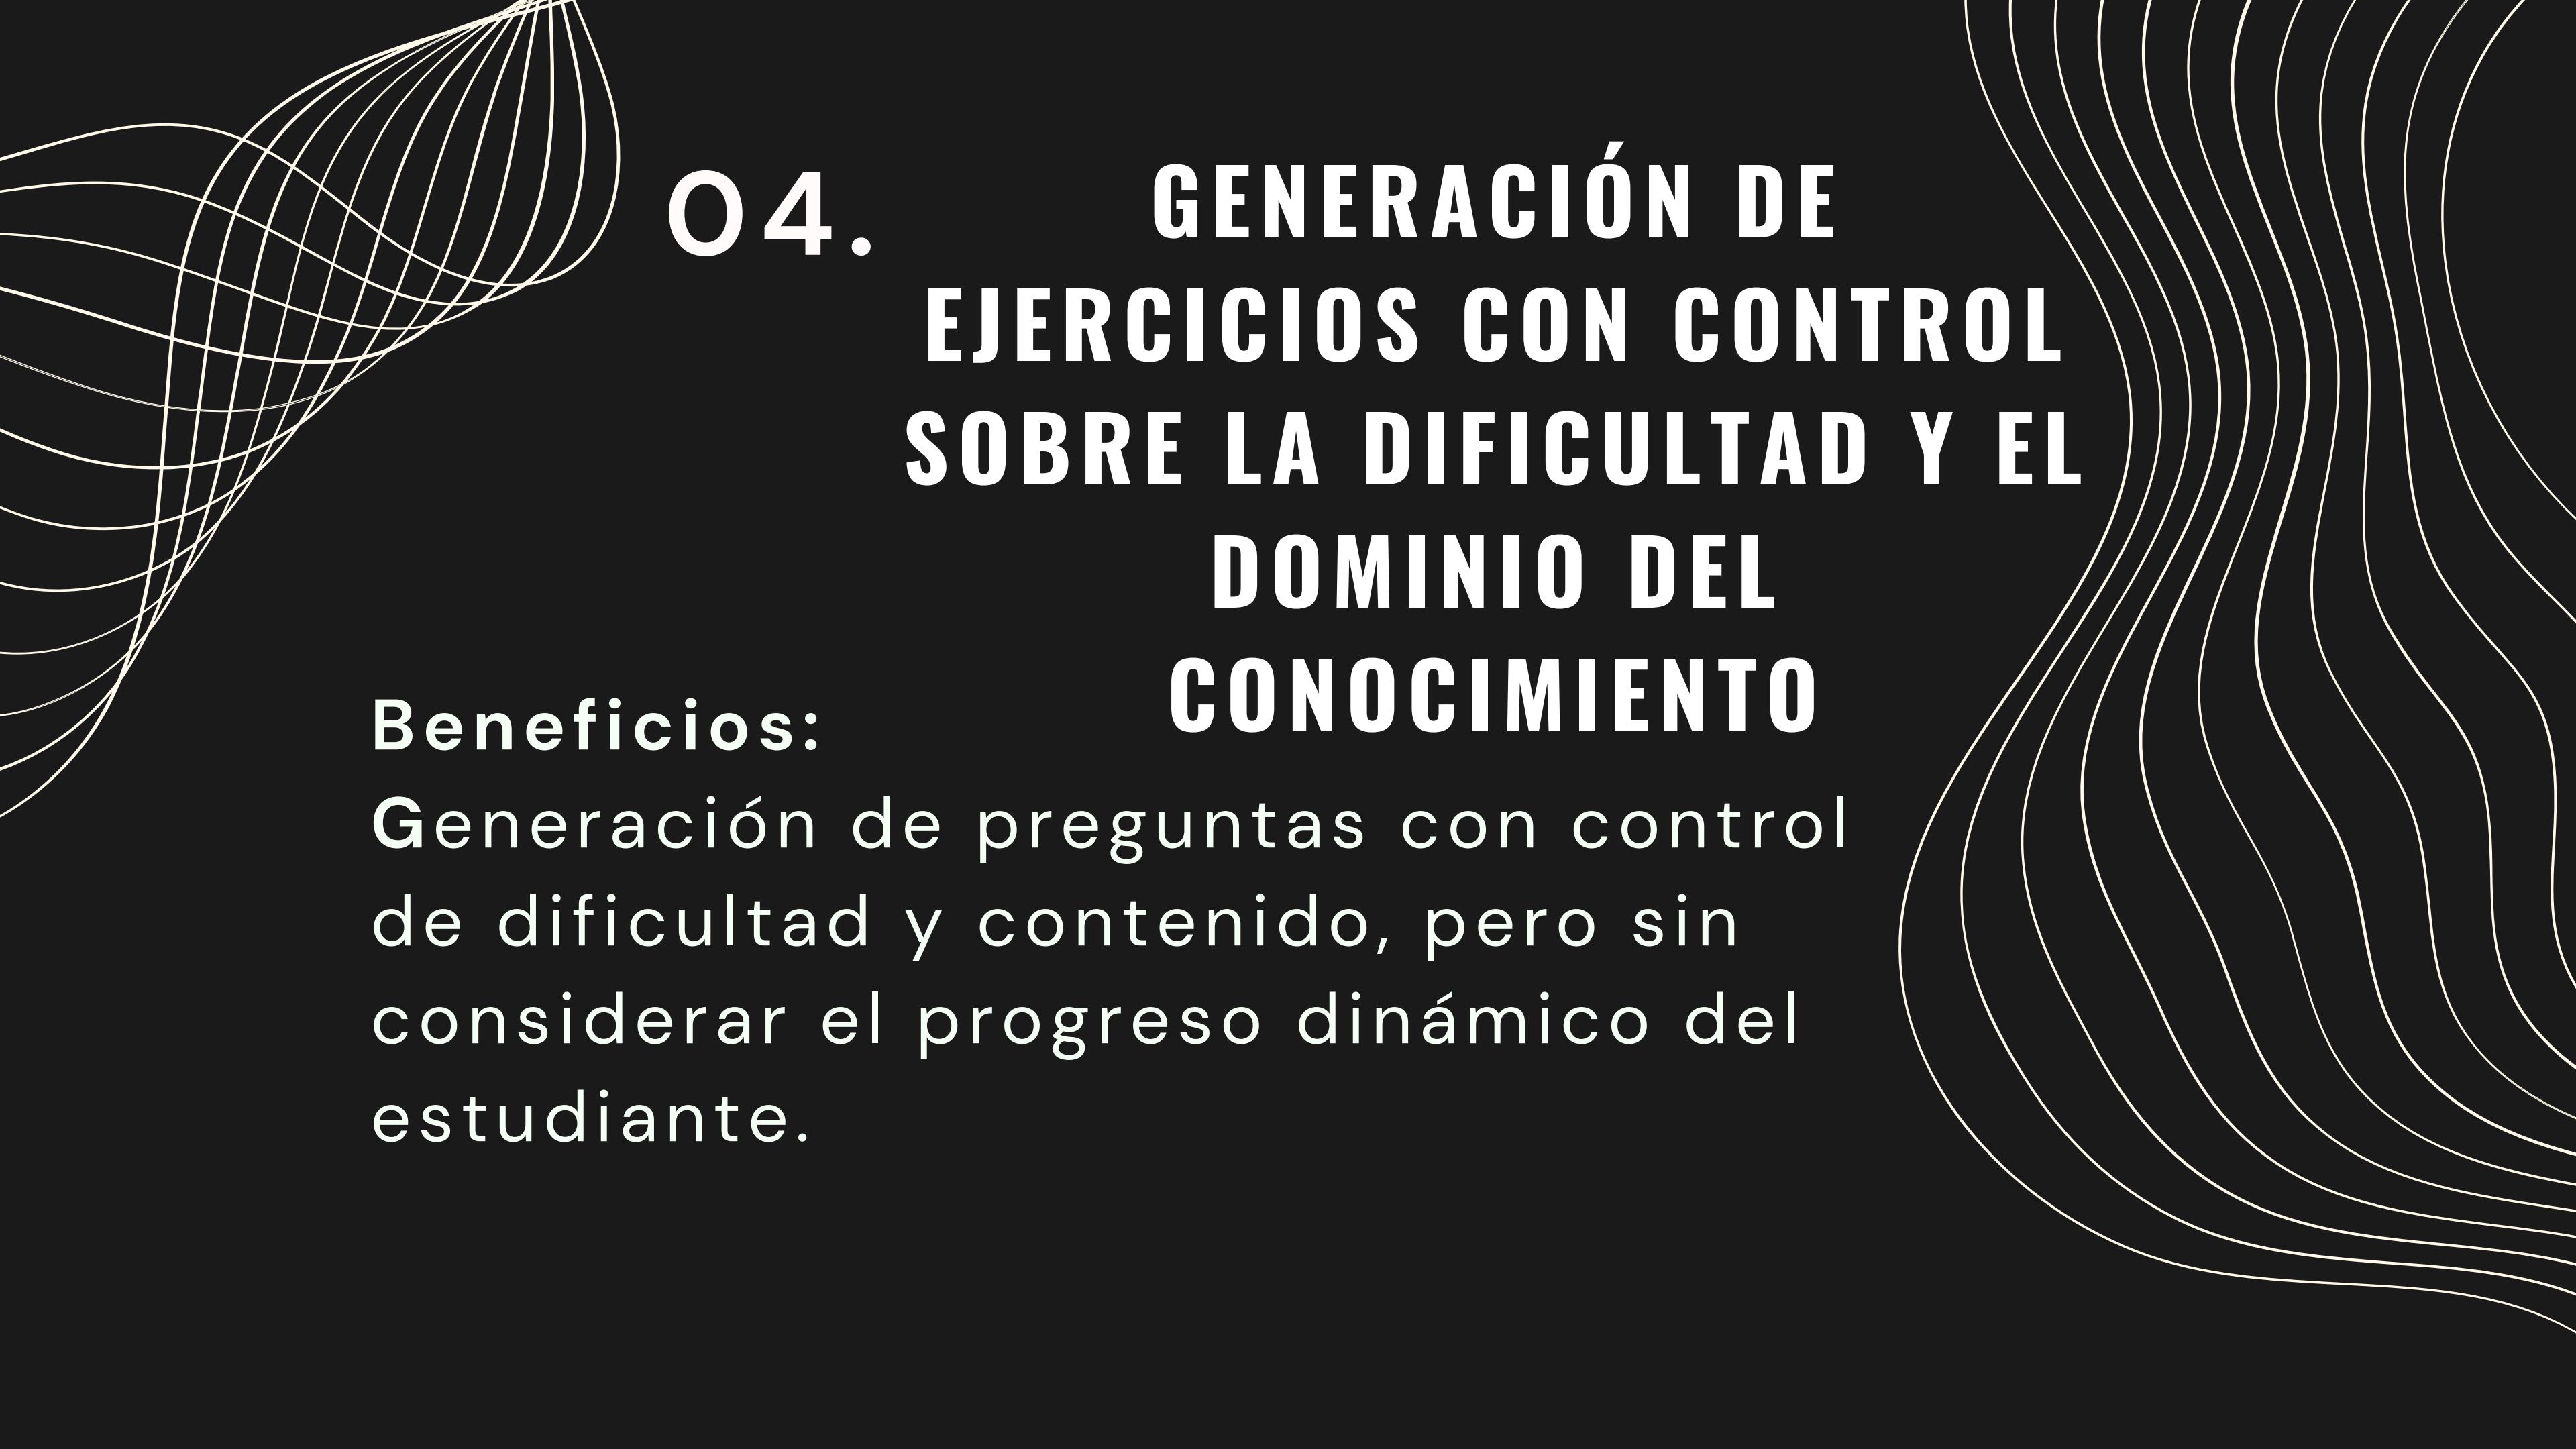
- Estos enfoques dependen de suposiciones simplistas sobre el proceso de aprendizaje y no consideran los avances recientes en los modelos de lenguaje para mejorar la estimación de los estados de conocimiento de los estudiantes.



03. MODELOS DE TRAZADO DE CONOCIMIENTO

Cómo lo supera el paper:

- Integra trazado de conocimiento con modelos de lenguaje preentrenados.
- Mejora la estimación del estado de conocimiento y genera ejercicios más personalizados.

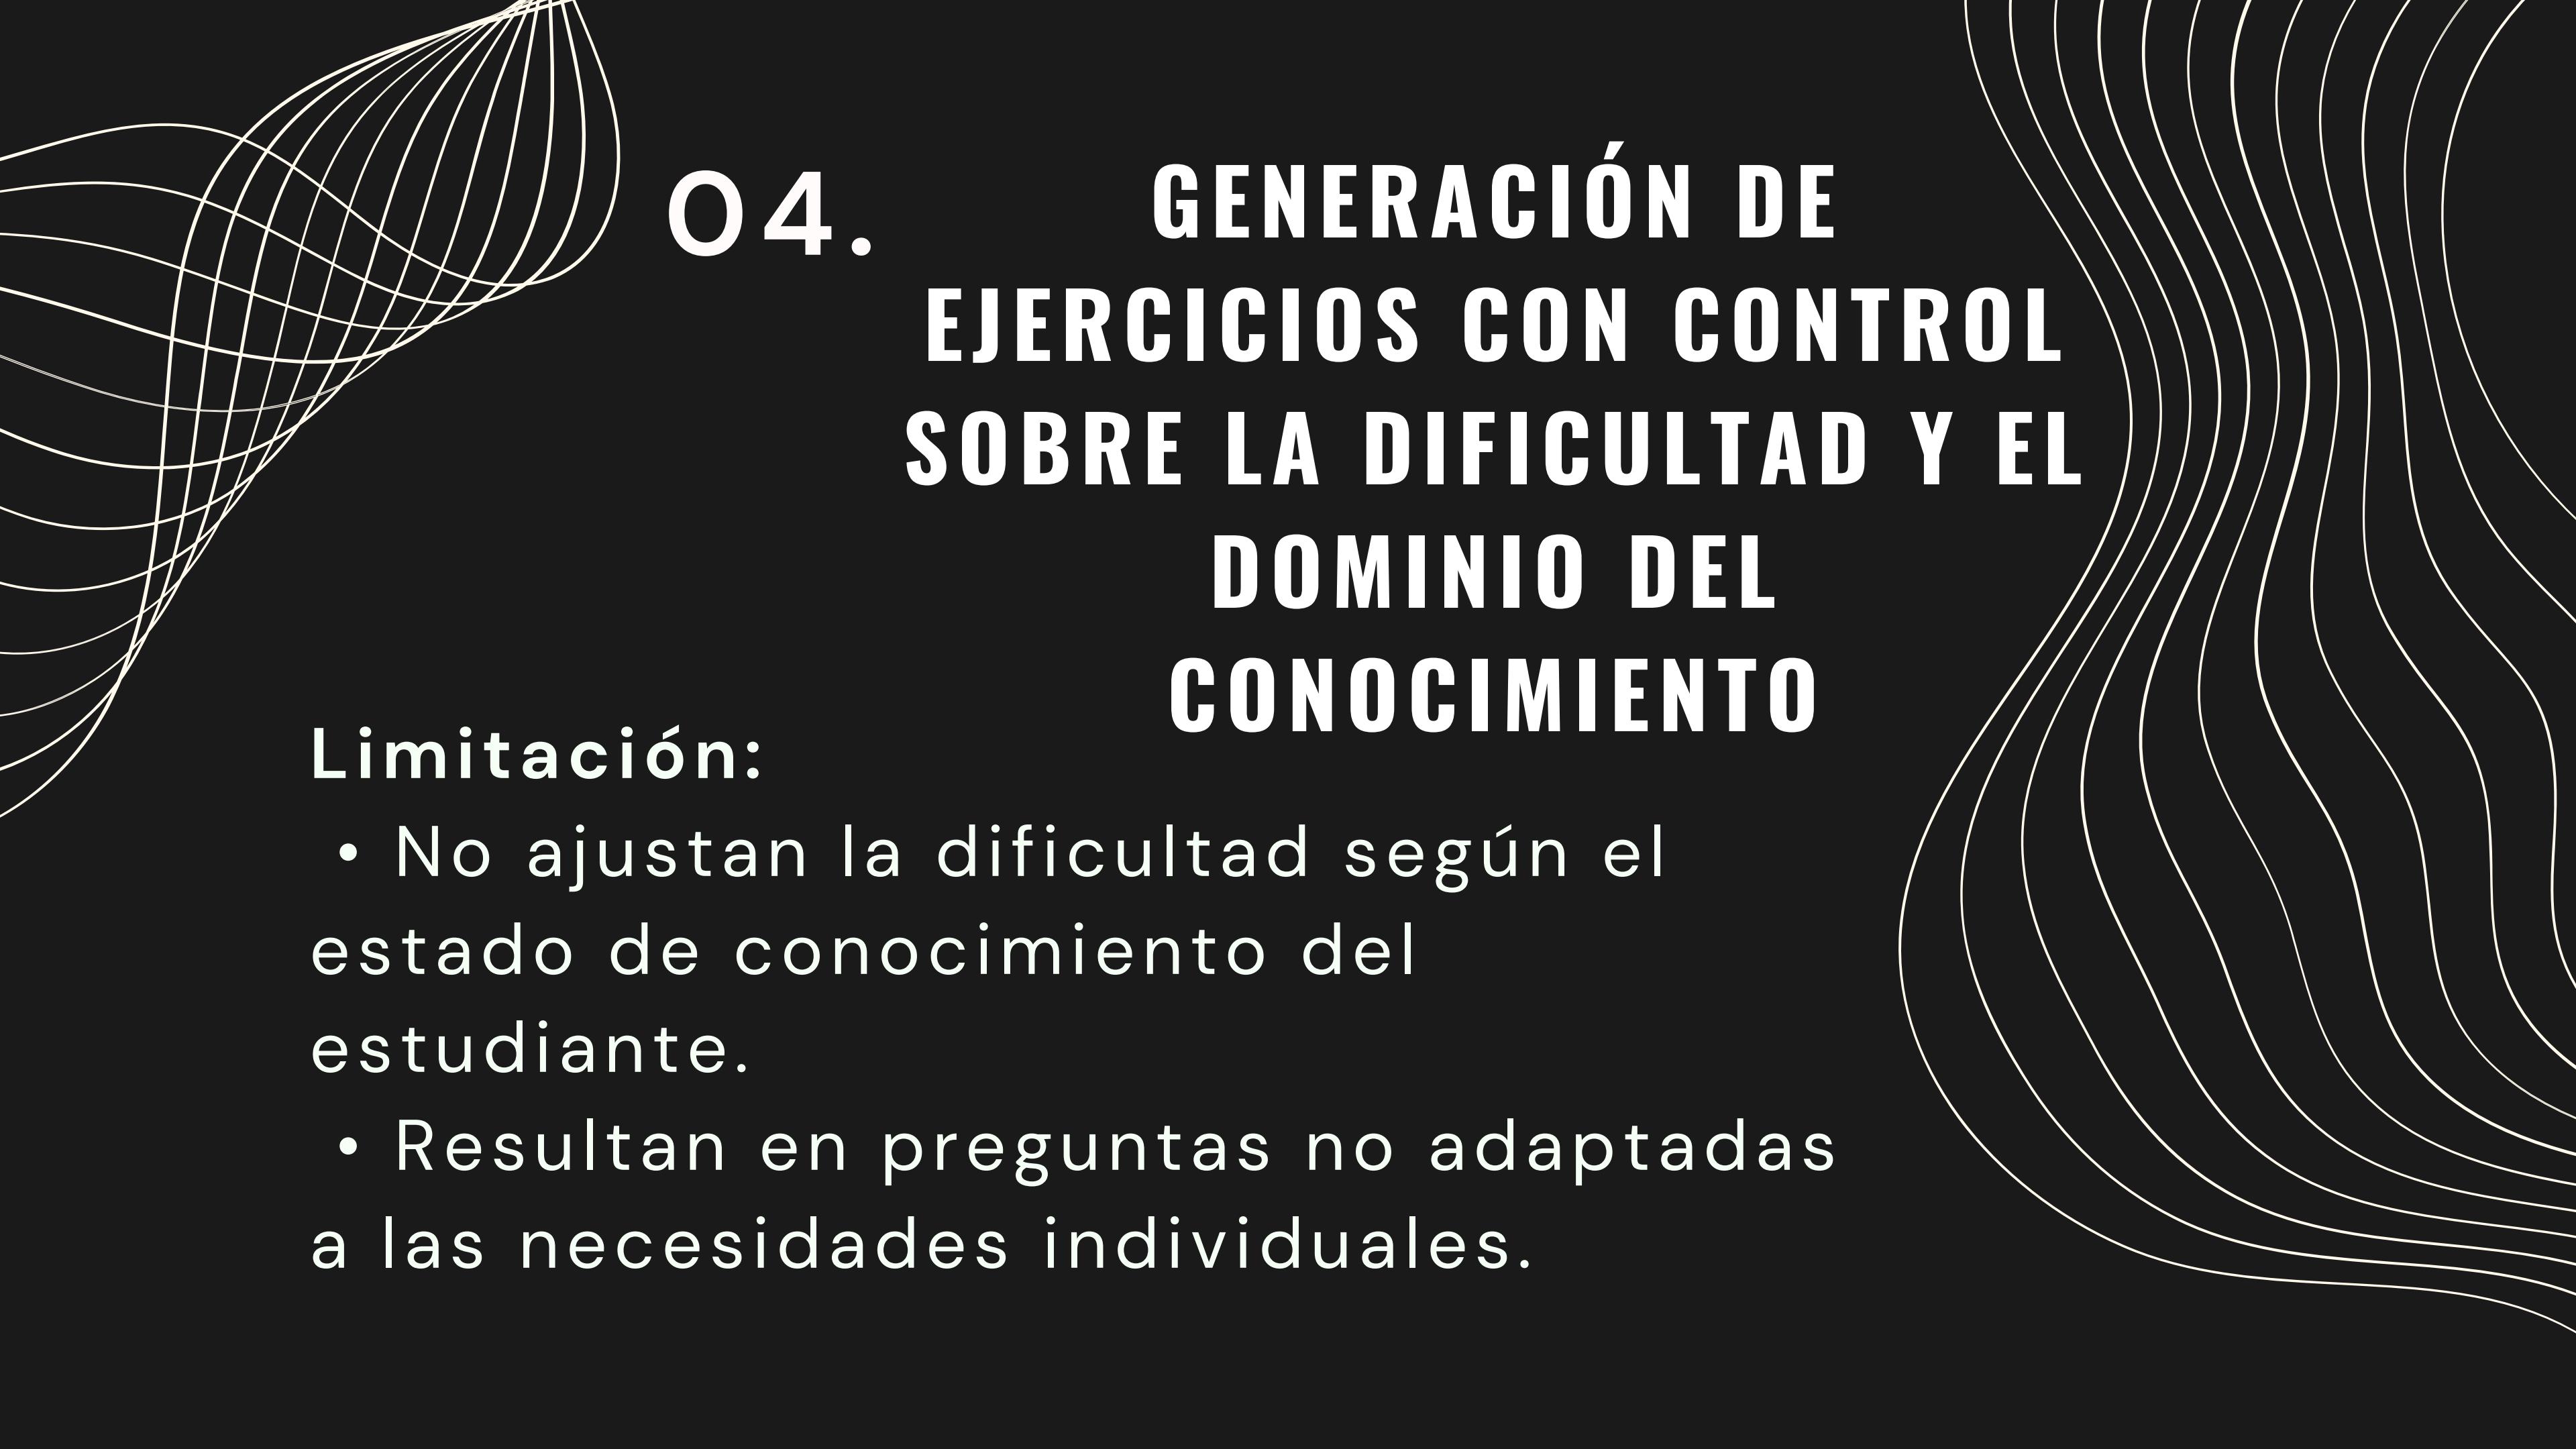


04.

GENERACIÓN DE EJERCICIOS CON CONTROL SOBRE LA DIFÍCULTAD Y EL DOMINIO DEL CONOCIMIENTO

Beneficios:

Generación de preguntas con control de dificultad y contenido, pero sin considerar el progreso dinámico del estudiante.

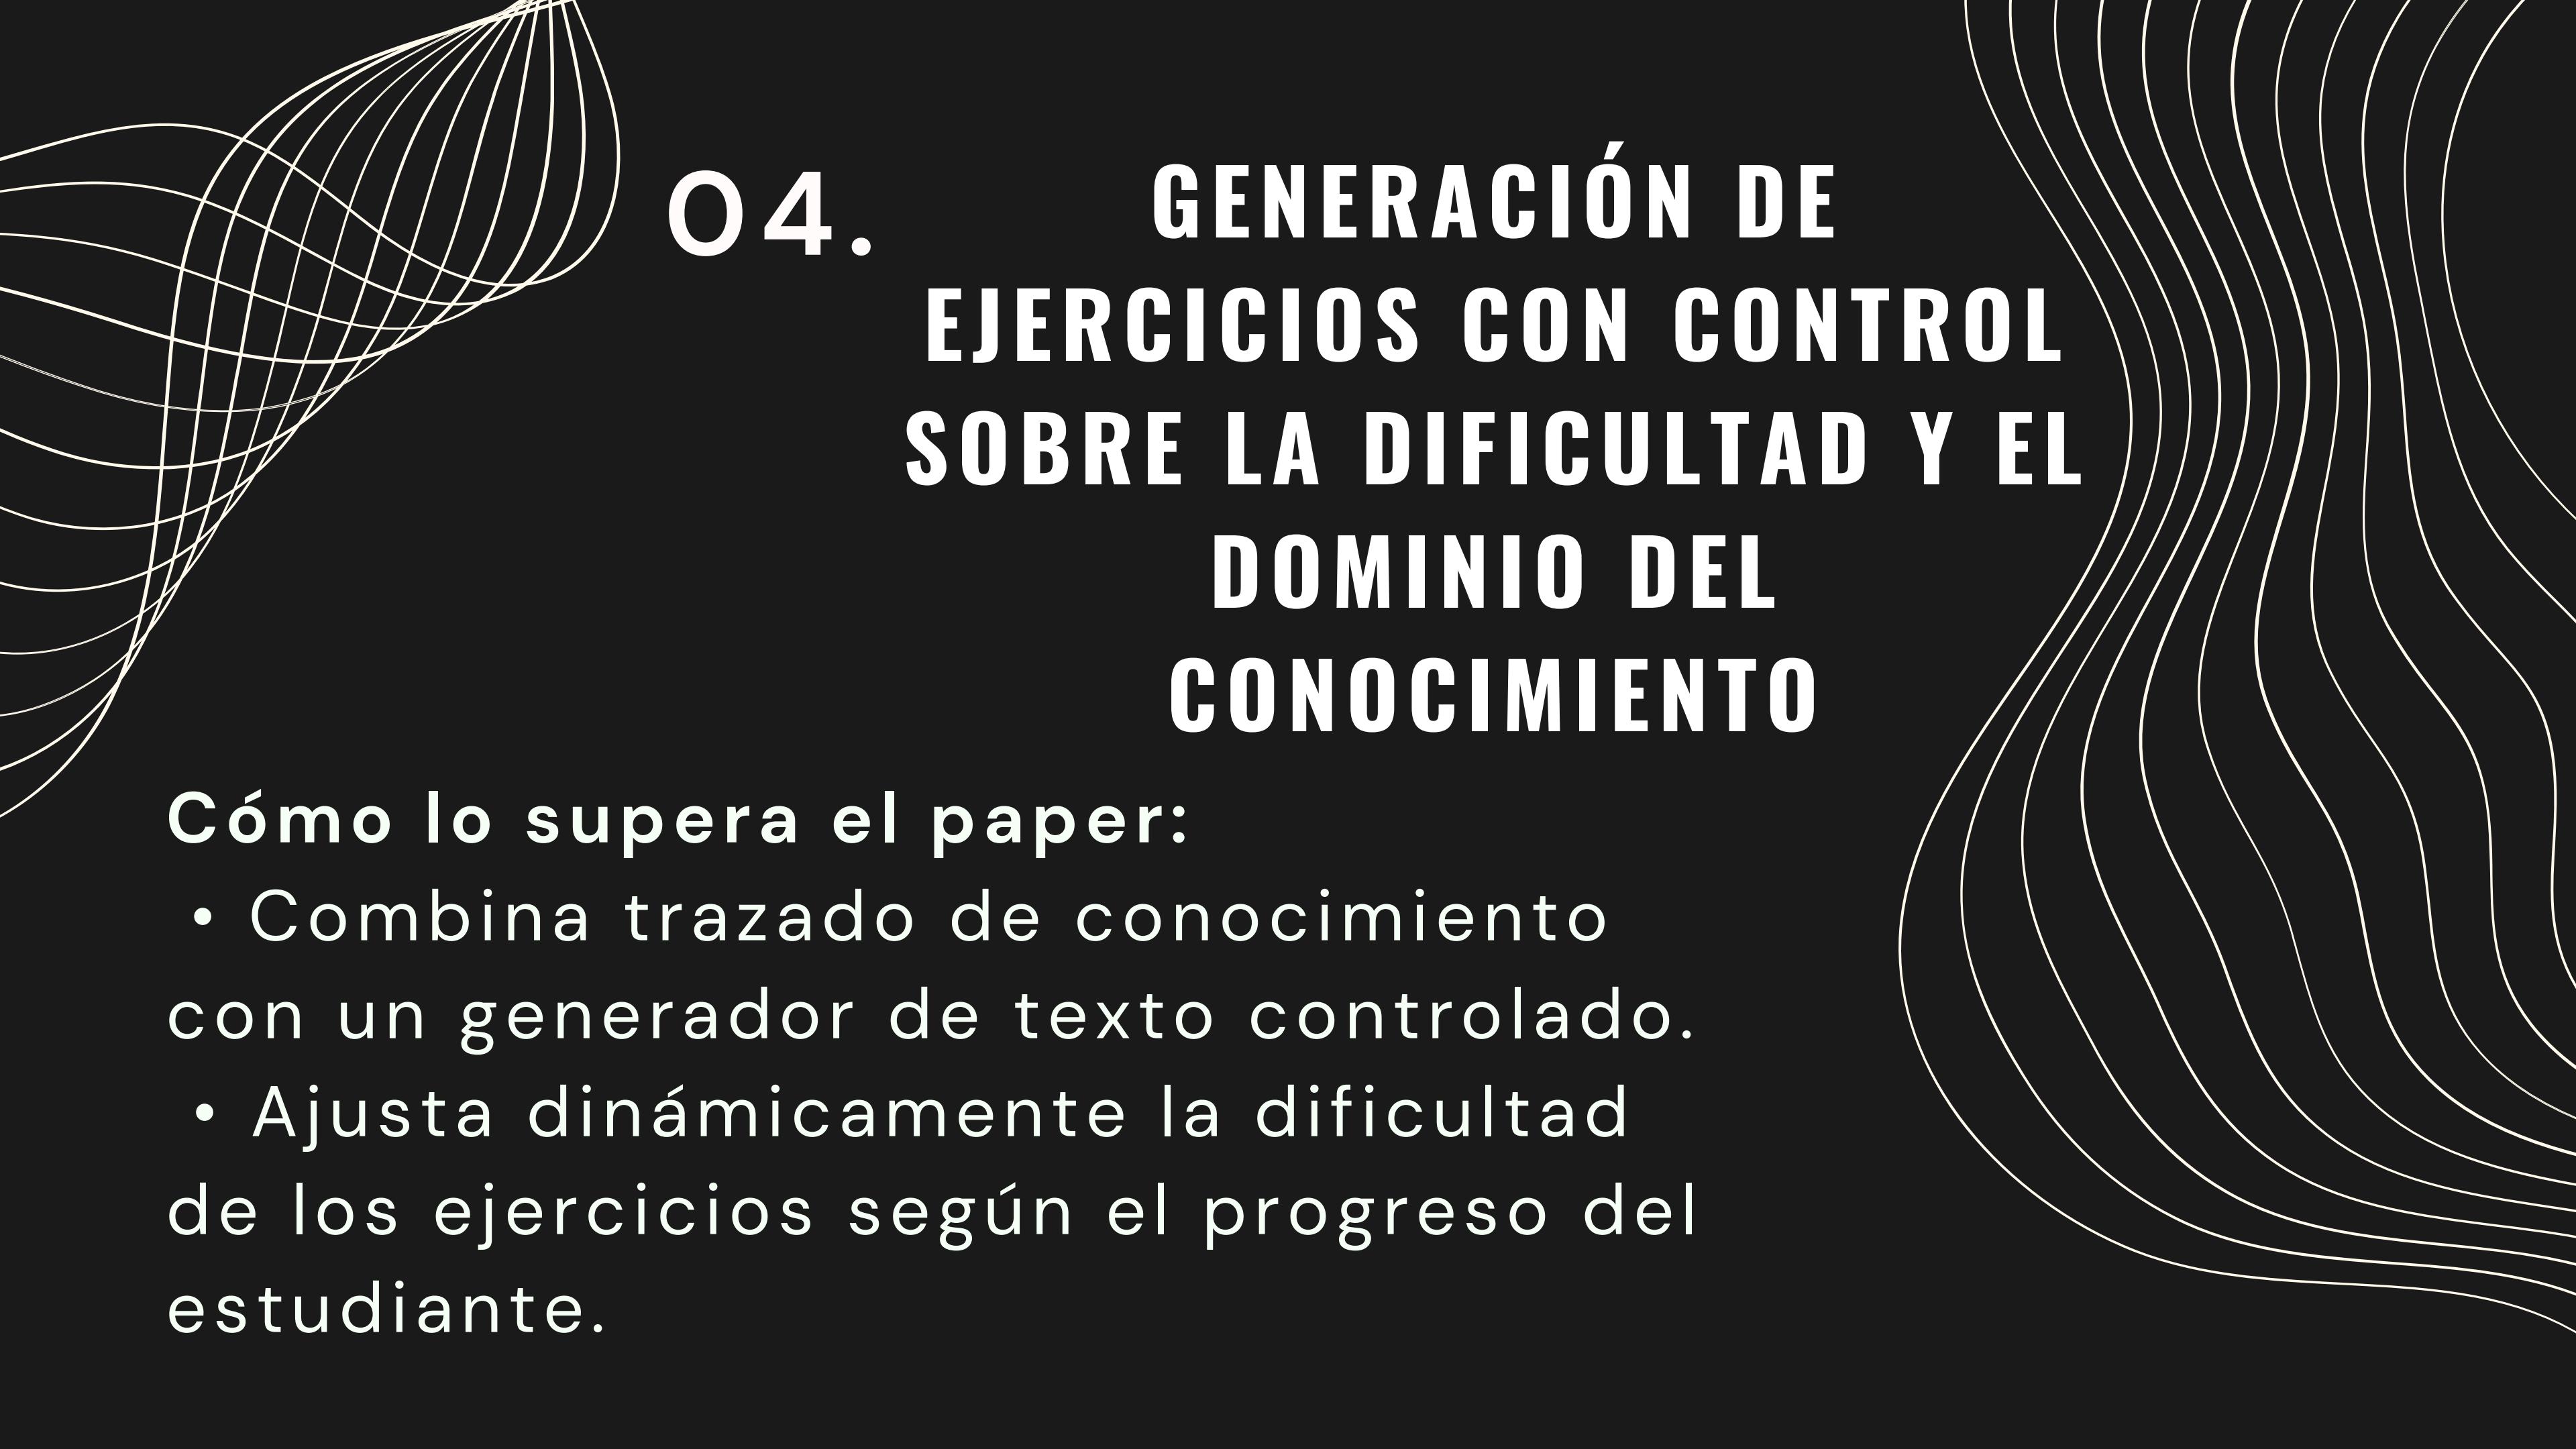


04.

GENERACIÓN DE EJERCICIOS CON CONTROL SOBRE LA DIFÍCULTAD Y EL DOMINIO DEL CONOCIMIENTO

Limitación:

- No ajustan la dificultad según el estado de conocimiento del estudiante.
- Resultan en preguntas no adaptadas a las necesidades individuales.

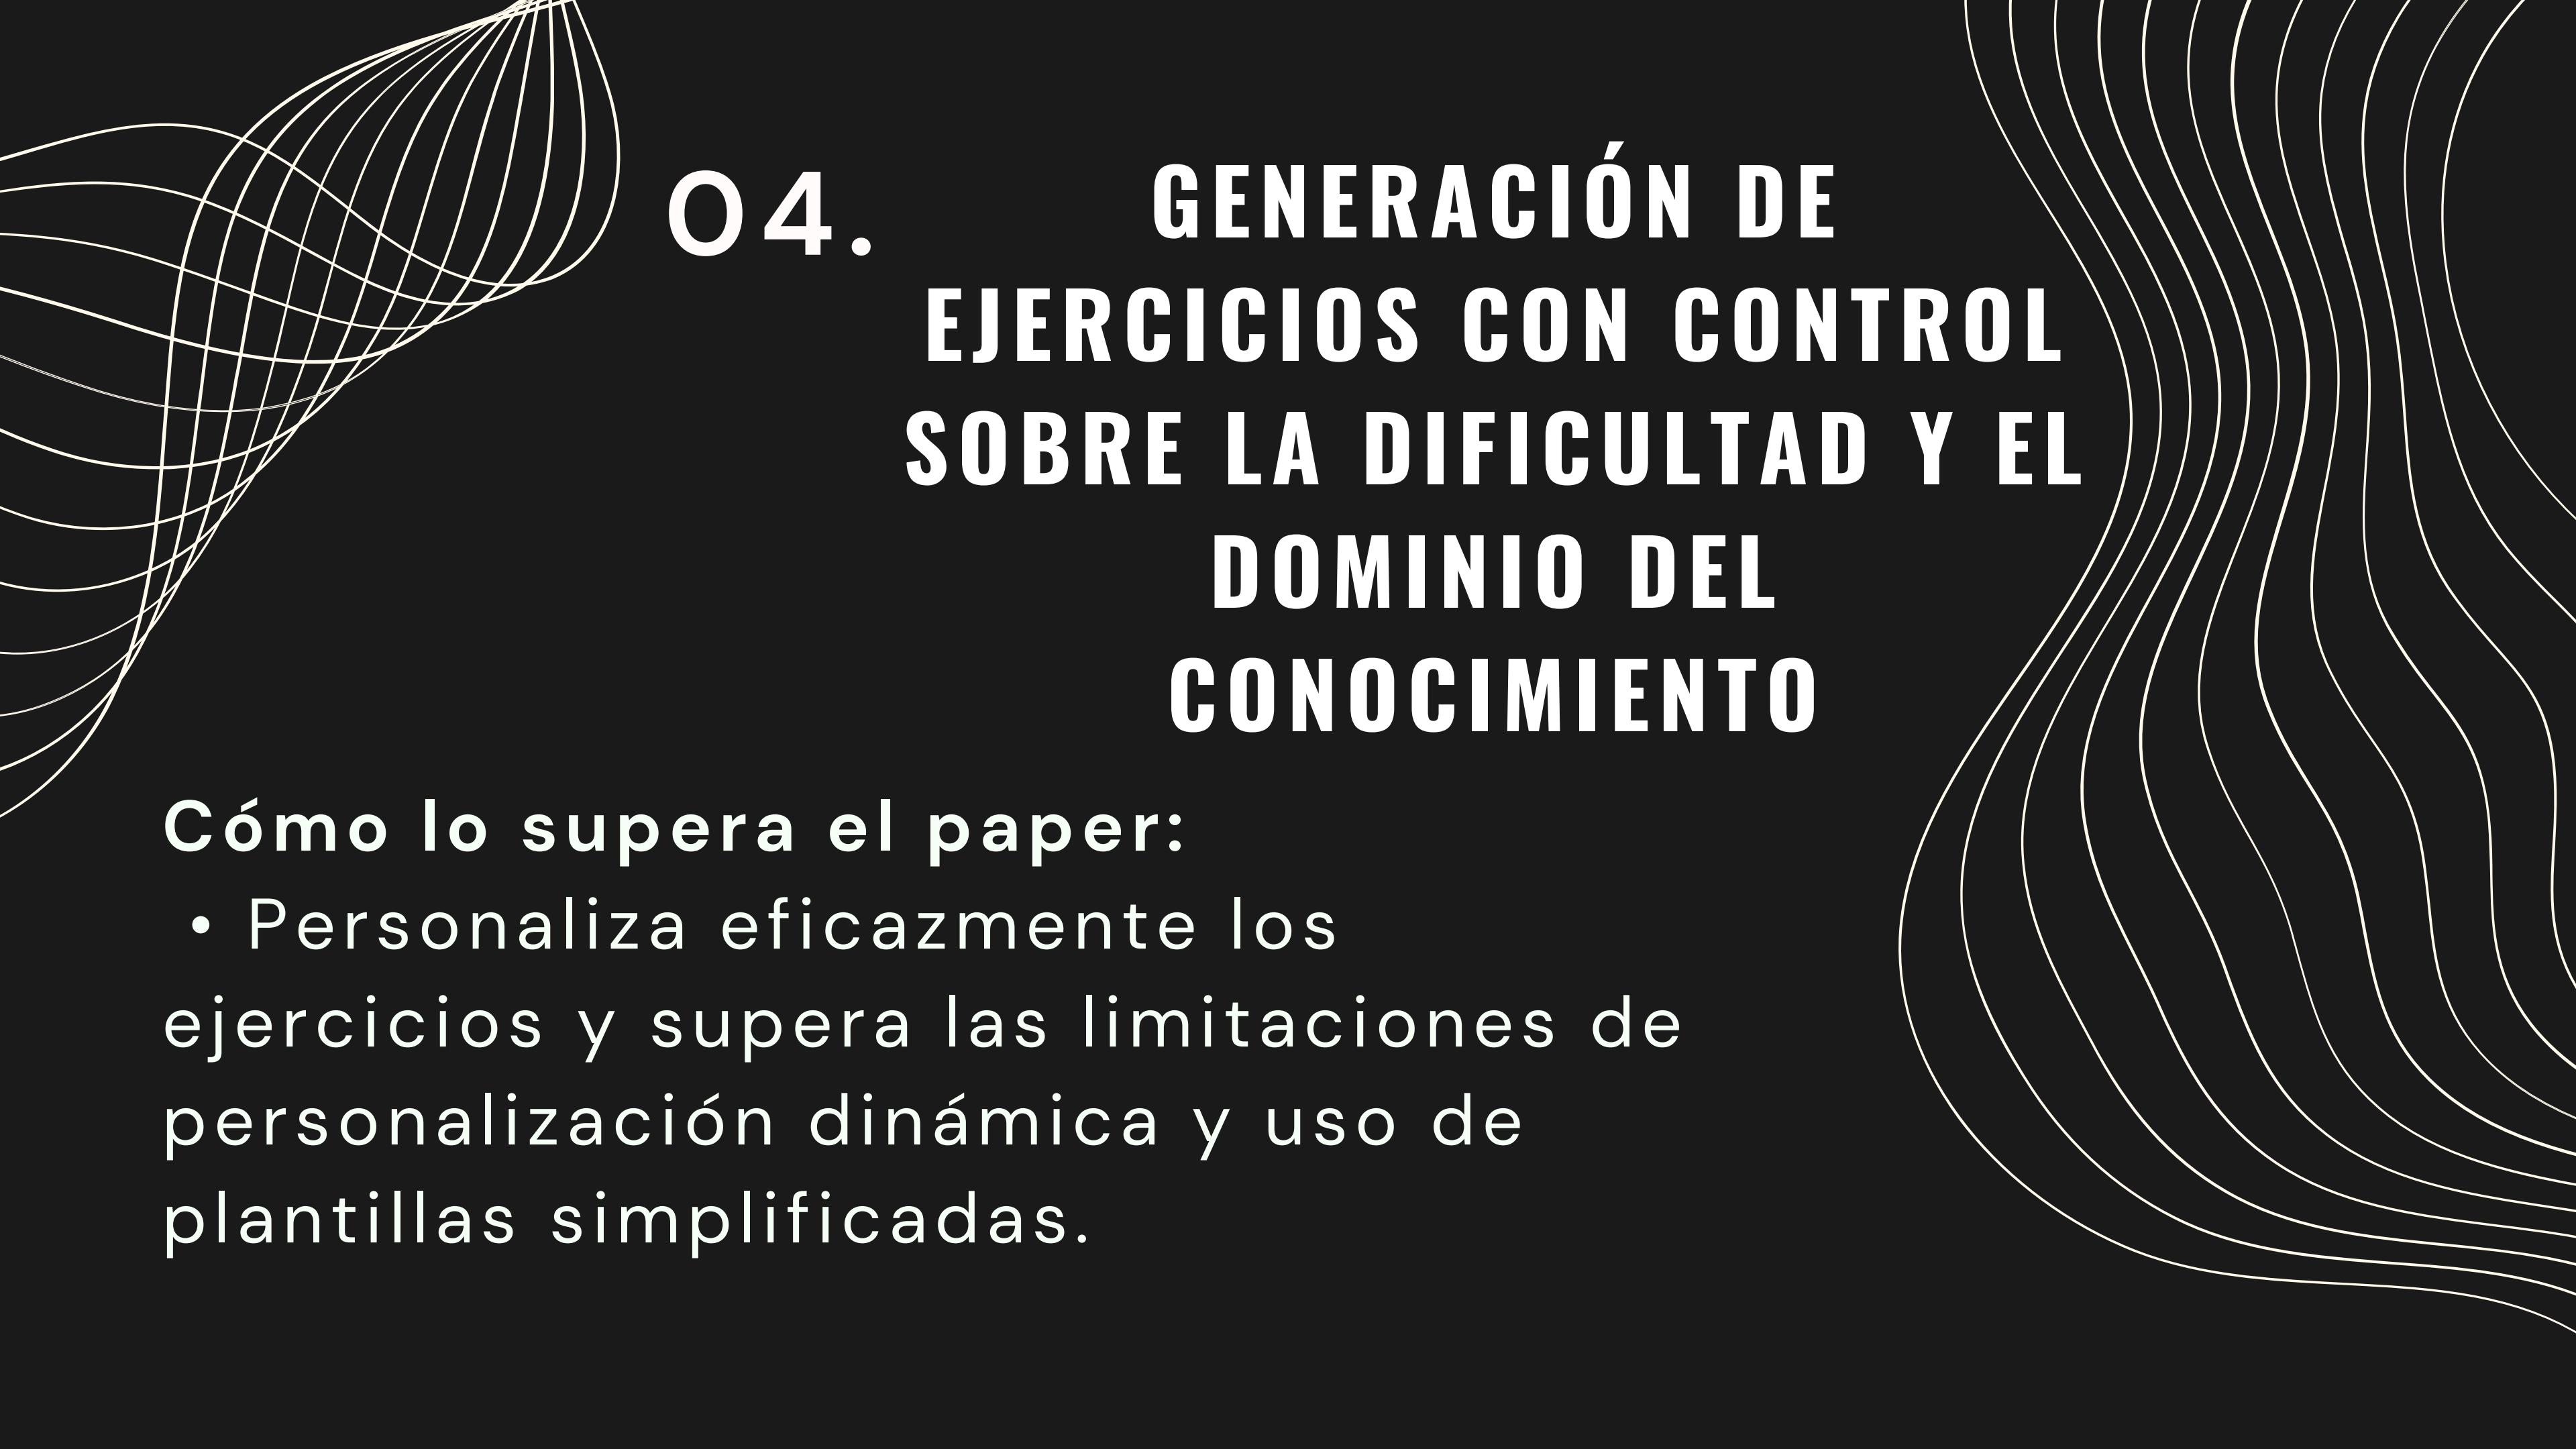


04.

GENERACIÓN DE EJERCICIOS CON CONTROL SOBRE LA DIFÍCULTAD Y EL DOMINIO DEL CONOCIMIENTO

Cómo lo supera el paper:

- Combina trazado de conocimiento con un generador de texto controlado.
- Ajusta dinámicamente la dificultad de los ejercicios según el progreso del estudiante.



04.

GENERACIÓN DE EJERCICIOS CON CONTROL SOBRE LA DIFICULTAD Y EL DOMINIO DEL CONOCIMIENTO

Cómo lo supera el paper:

- Personaliza eficazmente los ejercicios y supera las limitaciones de personalización dinámica y uso de plantillas simplificadas.

CONCEPTOS Y NOTACIÓN

$H_{\leq n} = \{(e_1, r_1), \dots, (e_n, r_n)\}$: historial de aprendizaje

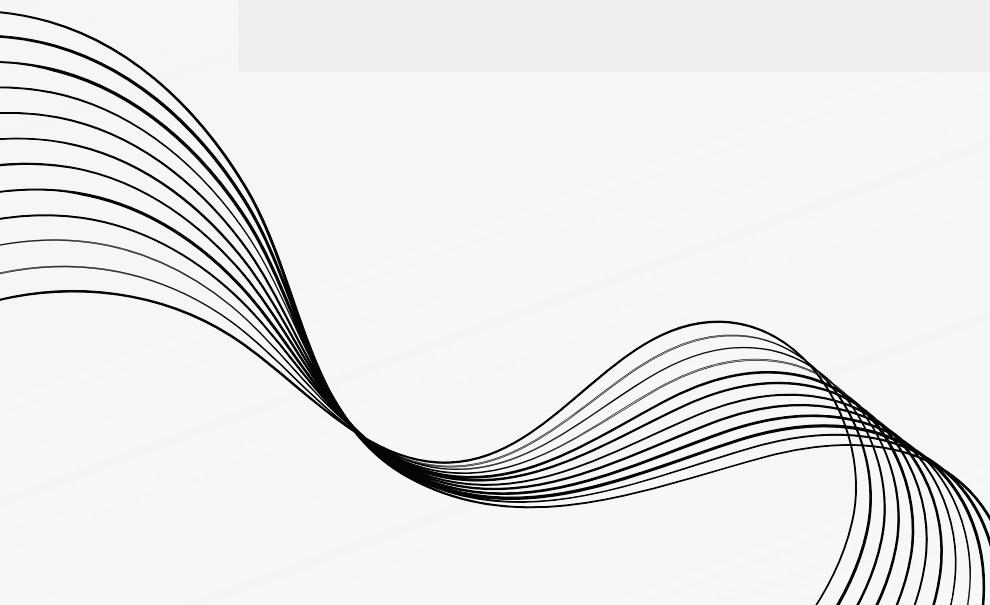
$e_i = \{w_{i,1}, \dots, w_{i,|e_1|}\}$: ejercicio, consiste en secuencia de palabras

$r_i \in \{0, 1\}^{|e_i|}$: etiqueta de correctitud para cada ejercicio

$C_{n+1} = \{c_1, \dots, c_{|C_{n+1}|} | c_* \in V\}$: componente de conocimiento, un subconjunto del vocabulario V que debe ser incluido en el output n+1

s_{n+1} : estado de conocimiento de un estudiante, vector $|V|$ -dimensional, con cada entrada la probabilidad de maestría de la palabra

d_{n+1} : la dificultad esperada de el ejercicio n+1, definida como el número errores en palabras que un estudiante haría traduciendo la oración.



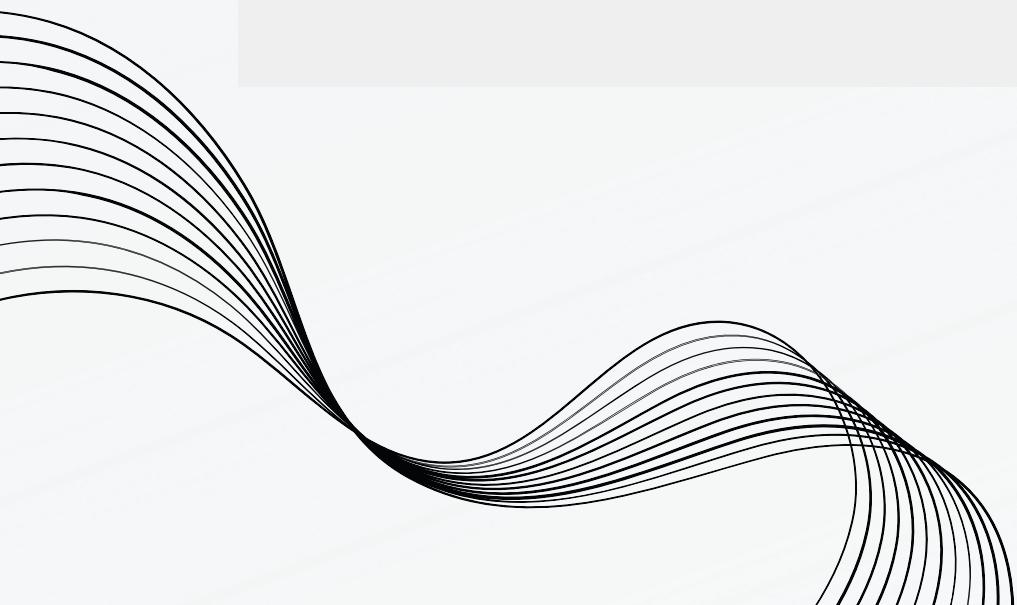
FORMALIZACIÓN DEL PROBLEMA

$$e_{n+1} = \underset{e}{\operatorname{argmax}} P(e | s_{n+1}, d_{n+1}, C_{n+1})$$

sujeto a:

$$\forall c \in C_{n+1} : \exists i, e_{n+1_{i:i+|c|}} = c$$

$$d_{n+1} = \sum_{w \in e_{n+1}} (1 - s_{n+1}[w])$$



MÉTODO PROPUESTO

01

02

03

04

05



KNOWLEDGE
TRACING - KT

CONTROLLABLE
EXERCISE
GENERATION

JOINT LEARNING
WITH
INCONSISTENCY
LOSS

CONSTRAINED
DECODING

PLUG-AND-PLAY
PERSONALIZED
GENERATION

KNOWLEDGE TRACING

Componente encargado de rastrear y estimar el estado de conocimiento de un estudiante a lo largo del tiempo basándose en su historial de respuestas

$$h_n = LSTM(\vec{e}_n + \vec{r}_n; h_{n+1})$$

$$s_{n+1} = sigmoid(W_s * h_n + b_s)$$

CONTROLLABLE EXERCISE GENERATION

Generador de ejercicios que utiliza el estado de conocimiento del estudiante para generar nuevos ejercicios adaptados a su nivel de habilidad y los temas que necesita practicar

$$x = [f_s(s); f_d(d); Emb(c_1, \dots, c_{|C|})]$$

$$L_G = - \sum_t^{|e|} logP(w_t | w_1, \dots, w_{t-1}, x)$$

JOINT LEARNING WITH INCONSISTENCY LOSS

Entrenamiento conjunto del knowledge tracer y el exercise generator. Se optimizan juntos para mejorar la coherencia entre el estado de conocimiento estimado y los ejercicios generados.

$$L_{inc} = |d - \sum_{w \in e} (1 - s[w])|$$

LEXICAL DIFFICULTY CONSTRAINED DECODING

Método utilizado durante el proceso de generación de ejercicios para garantizar que el contenido generado cumpla con contener las palabras objetivo y tener la dificultad deseada.

$$Y_t = \underset{y_{$$

$$F_c(y_{$$

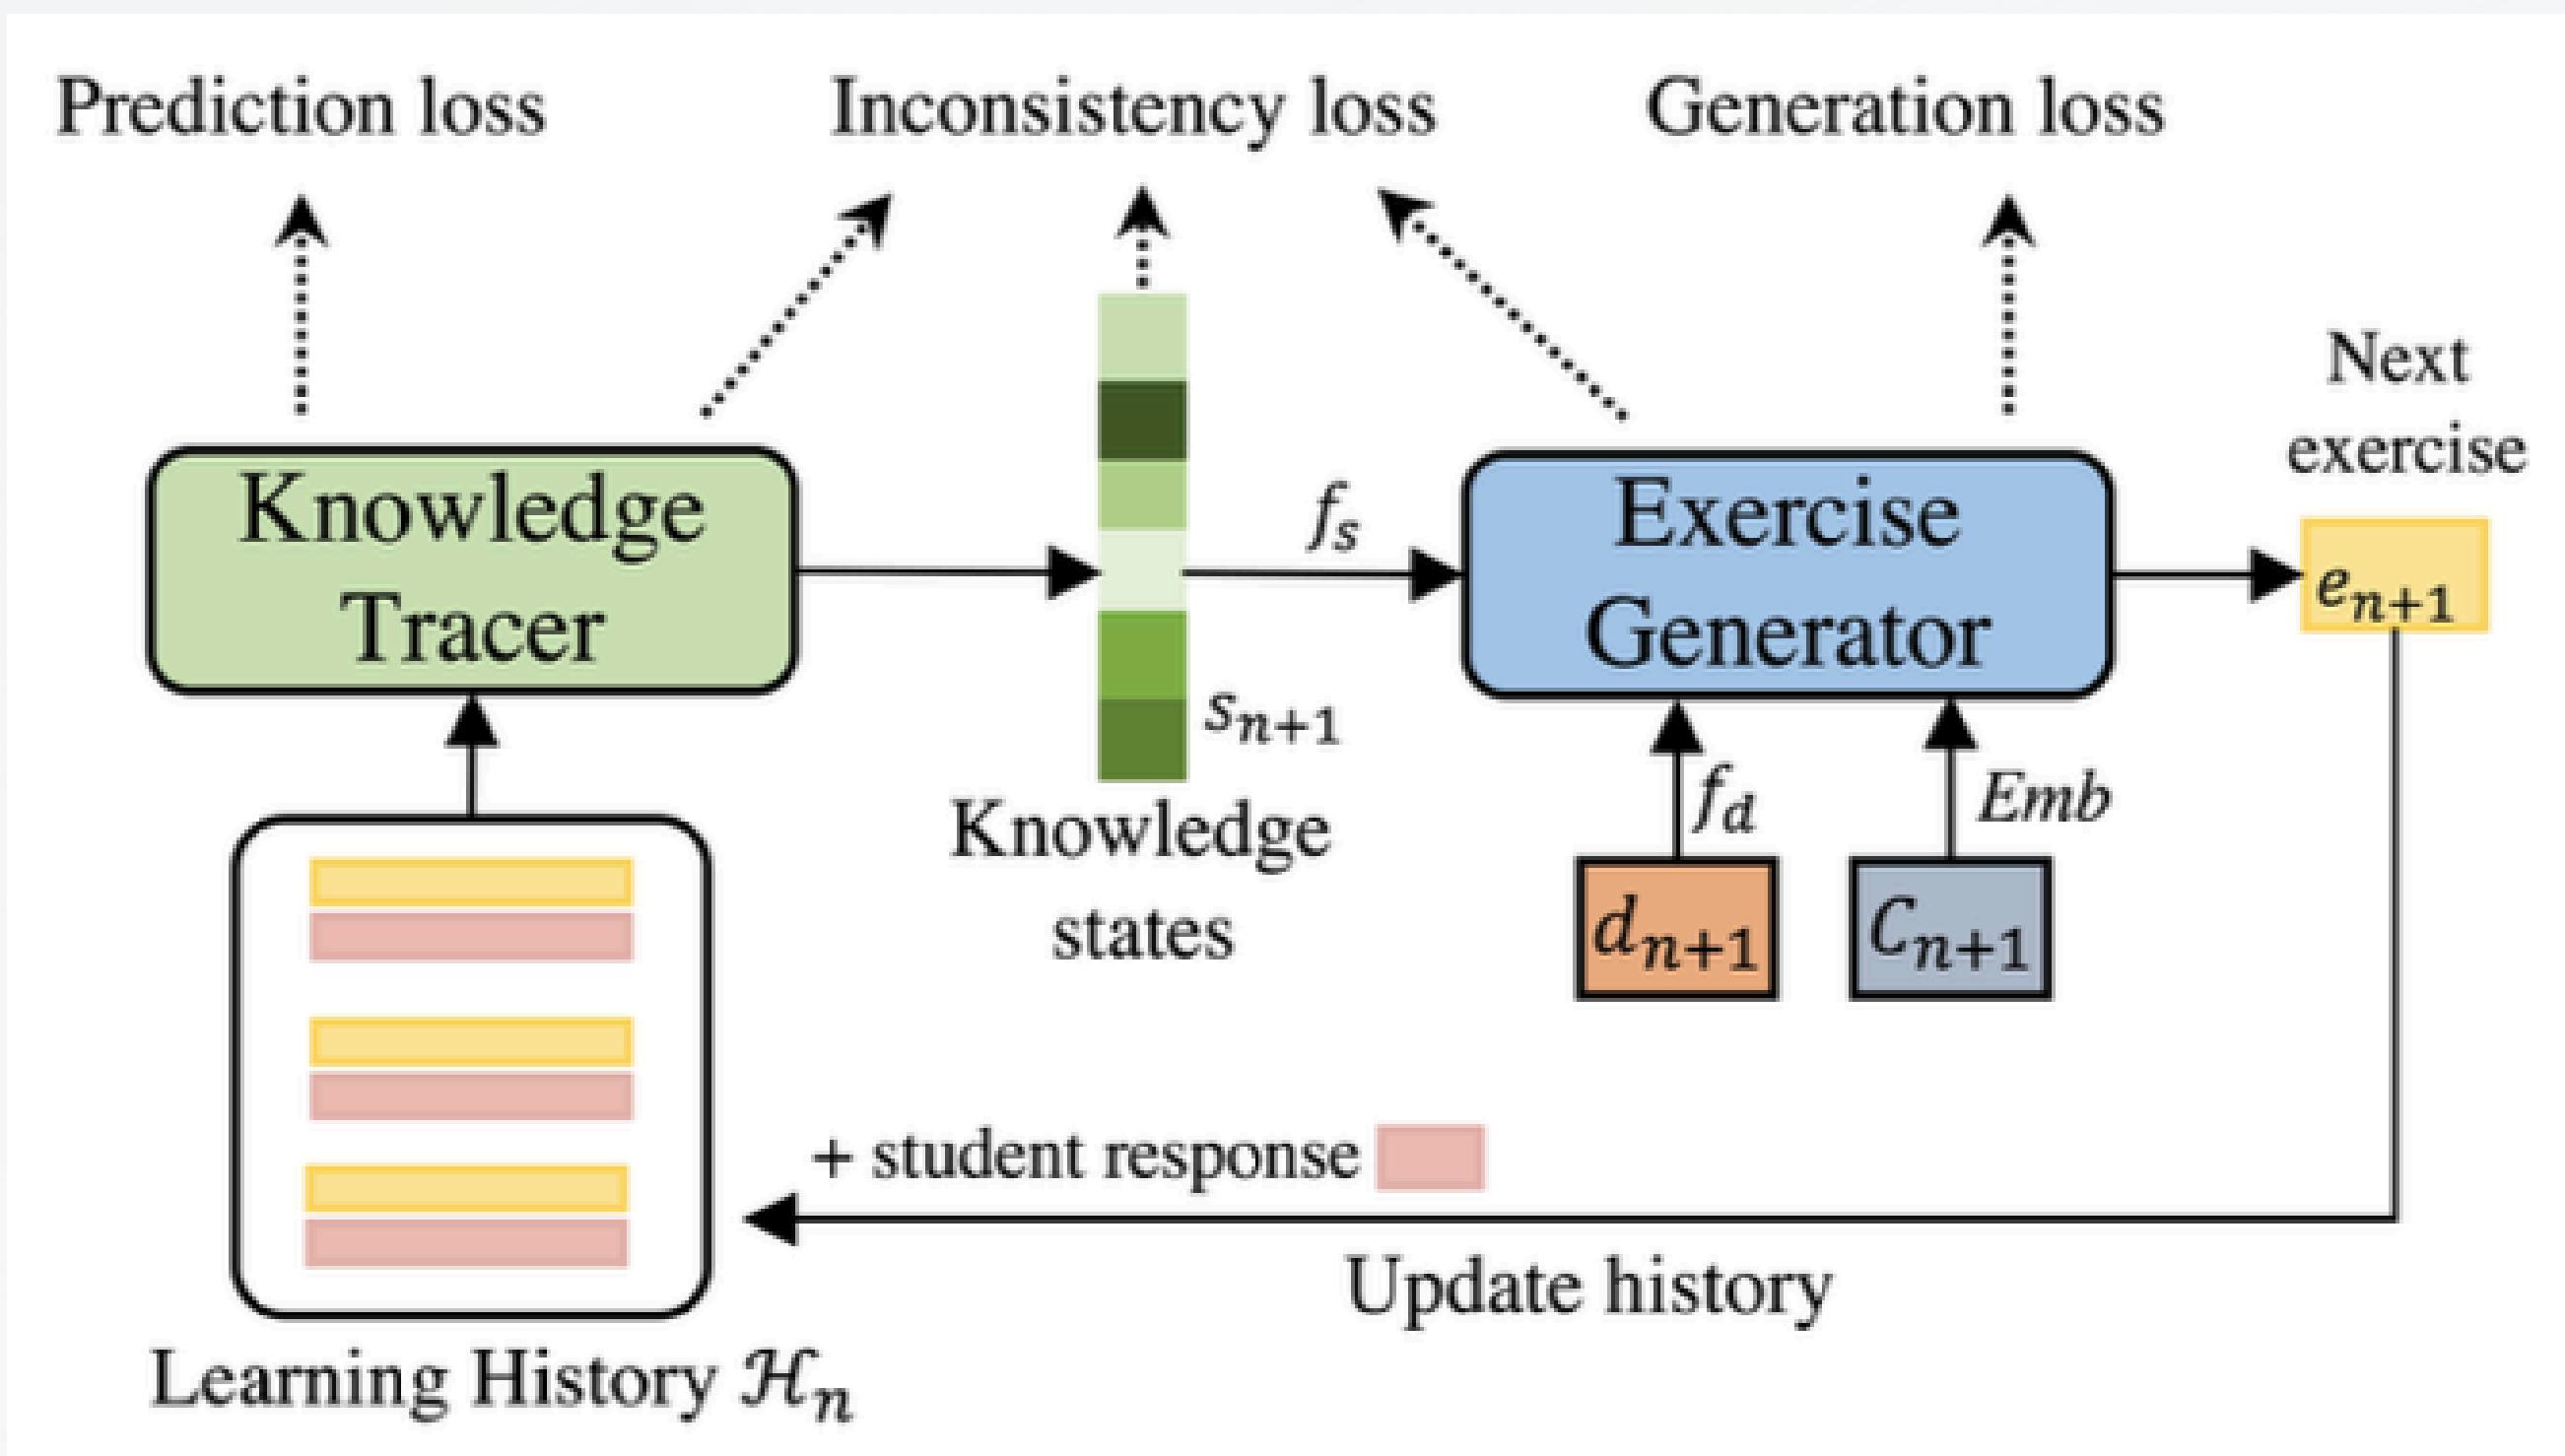
$$F_d(y_{$$

PLUG-AND-PLAY PERSONALIZED GENERATION

Capacidad del sistema de integrarse con algoritmos de recomendación de aprendizaje personalizado, mejorando sistemas existentes recomendando qué tipo de ejercicio debe resolver el estudiante a continuación para maximizar su aprendizaje.

$$s_{n+1} = \sum_{r \in \{0,1\}^{|e|}} P(r) * T(s_n, (e, r))$$

FLUJO DEL SISTEMA



4.1 RESULTADOS: KNOWLEDGE TRACING

- El modelo DKLM fue evaluado con datos reales de Duolingo. Se utilizó el AUC para medir su capacidad de predecir el conocimiento de los estudiantes tanto en ejercicios ya vistos como en nuevos.
- El modelo DKLM ($\tau=2$) es el que mejor rendimiento mostró, obteniendo los AUC más altos en ambas categorías: "word-level" y "exercise-level", tanto para ejercicios vistos como no vistos.
- El rendimiento de DKLM con $\tau=2$ es especialmente notable en la predicción de ejercicios no vistos, alcanzando un AUC de 71.74 en el nivel de ejercicio.

Model	Word-level		Exercise-level	
	Seen	Unseen	Seen	Unseen
Ensemble	73.41	70.58	65.55	64.93
Standard DKT	80.46	75.54	72.32	71.54
DKT _{LM, τ=0.5}	80.47	75.51	72.39	71.47
DKT _{LM, τ=1.0}	80.49	75.54	72.38	71.49
DKT _{LM, τ=2.0}	80.55	75.69	72.41	71.74
DKT _{LM, τ=3.0}	80.54	75.48	72.33	71.52
DKT _{LM, τ=5.0}	80.31	75.46	72.28	71.50

- Tabla: resultados del AUC para los diferentes modelos, incluyendo DKTL (τ=2), KT y DKT.

4.2 RESULTADOS: GENERACIÓN DE EJERCICIOS

Models	BLEU ↑		METEOR ↑		KC-Coverage (%) ↑		D-MAE ↓		Invalid (%) ↓
	Seen	Unseen	Seen	Unseen	Seen	Unseen	Seen	Unseen	
EG _H	9.23	<0.01	18.79	6.05	14.26	2.49	0.396	1.500	0.071
AQG _{H+d}	10.28	<0.01	20.15	7.16	15.84	2.95	0.463	0.985	1.674
EG _C	18.41	5.21	45.36	36.14	99.77	90.63	0.367	0.837	0.301
EG _{C+d}	11.84	15.94	40.89	42.10	96.23	91.62	0.564	0.679	0.385
APEG _{s+C+d}	22.47	34.60	56.15	44.01	99.61	95.71	0.246	0.604	0.283
- joint learning	22.01	33.15	55.80	42.85	99.63	94.08	0.251	0.619	0.281
- constrained decoding	21.58	32.06	55.43	40.49	99.59	94.77	0.263	0.681	0.277
Upper bound	53.65	41.24	74.97	52.10	99.75	95.96	0.060	0.302	0.233

- El modelo APEGs+C+d fue evaluado para la generación de ejercicios adaptados al conocimiento de los estudiantes. Se usaron métricas como BLEU y KC-Coverage para medir la calidad de los ejercicios.
- APEGs+C+d obtiene los mejores resultados en KC-Coverage, cubriendo más del 99% de los componentes de conocimiento.
- BLEU y METEOR son métricas de calidad de generación de texto que evalúan la similitud entre los ejercicios generados y los esperados.

4.3 RESULTADOS: IMPACTO DE LA DECODIFICACIÓN CON LOOKAHEAD

- La estrategia de decodificación con lookahead mejora el rendimiento de la generación de ejercicios en el modelo propuesto.
- Con lookahead, el modelo reduce el error absoluto medio (D-MAE) en la generación de ejercicios.
- El uso de lookahead también mejora la cobertura de componentes de conocimiento (KC-Coverage) al 99.3%.

	BLEU ↑	Coverage (%) ↑	D-MAE ↓
w/o lookahead	20.46	99.18	0.263
w/ lookahead	21.20	99.30	0.257

Table 3: Comparison of generation performance with and without lookahead on the validation set.

4.4 RESULTADOS: CALIBRACIÓN DE DIFICULTAD

- El modelo ajusta dinámicamente la dificultad de los ejercicios generados en función del progreso del estudiante.
- El modelo ajusta la dificultad de los ejercicios de manera precisa a lo largo de distintos niveles de conocimiento del estudiante.
- La calibración dinámica asegura que los estudiantes reciban ejercicios de dificultad apropiada para su progreso.

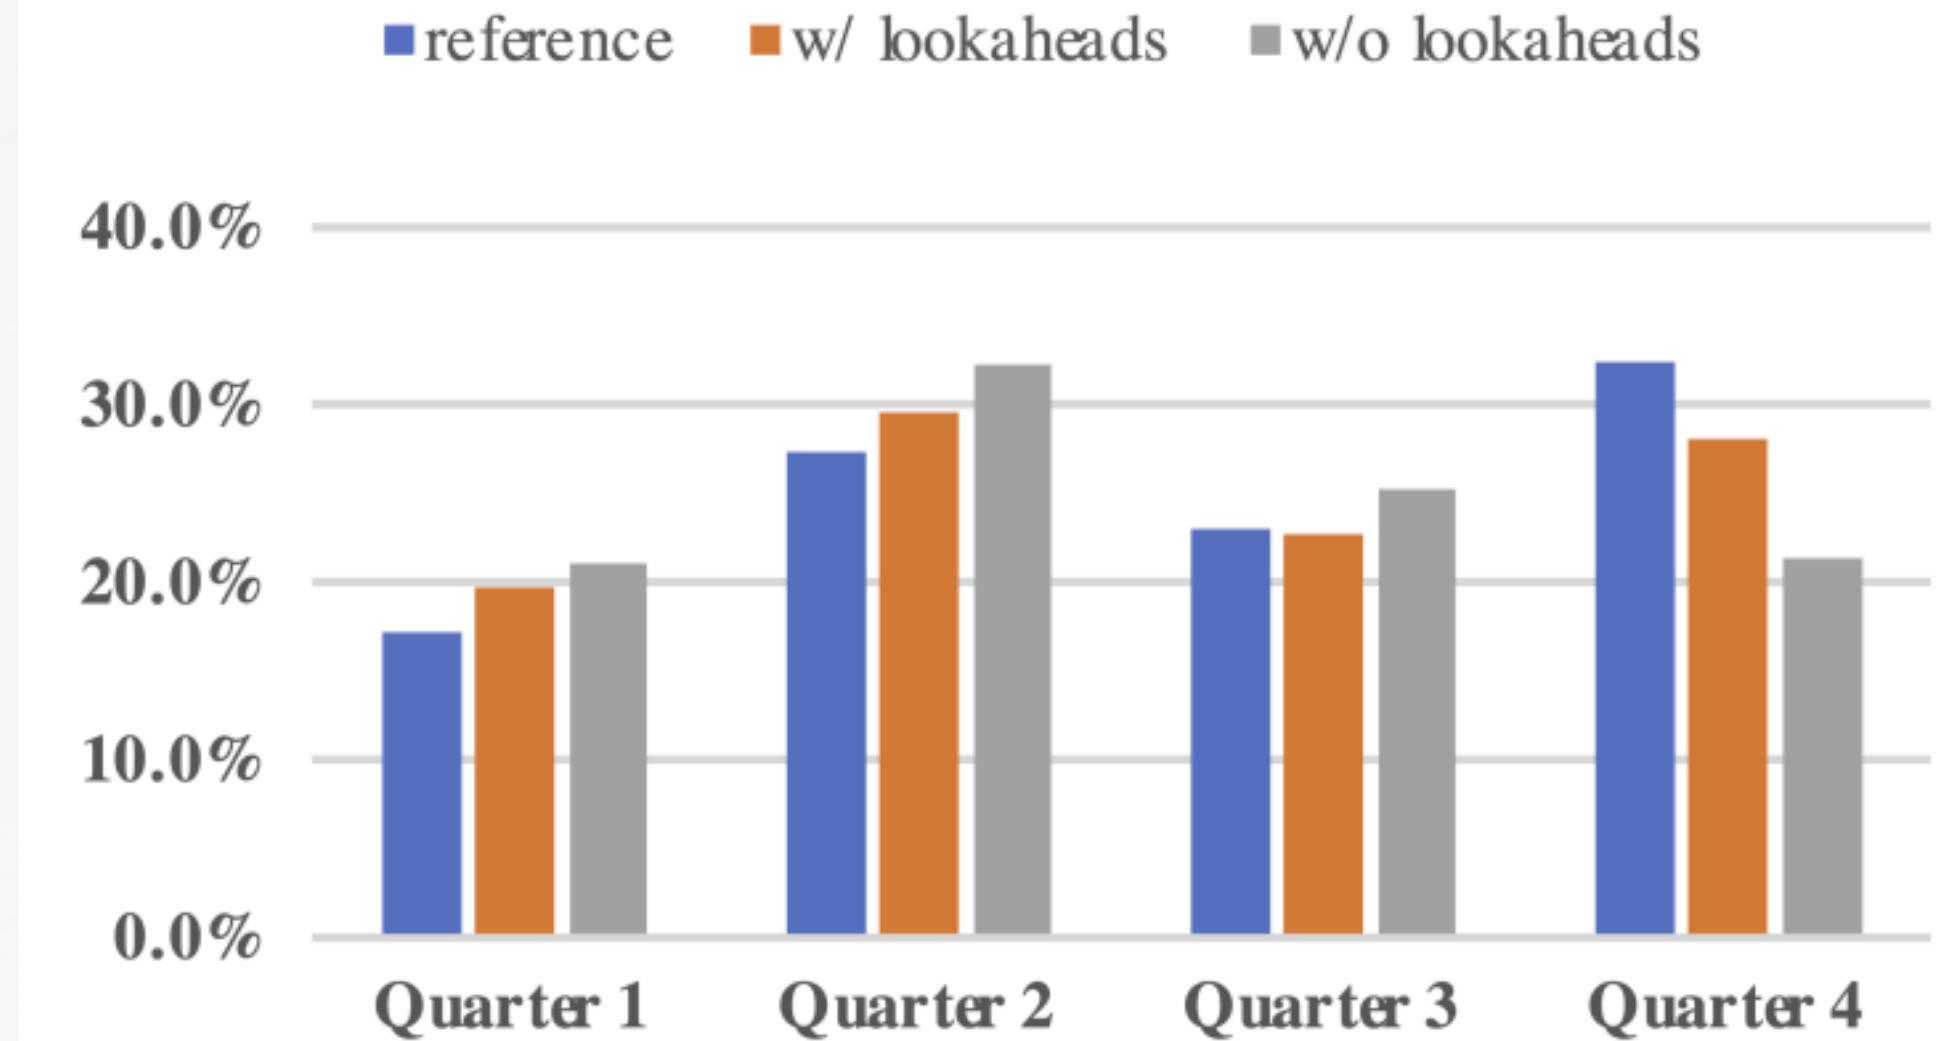


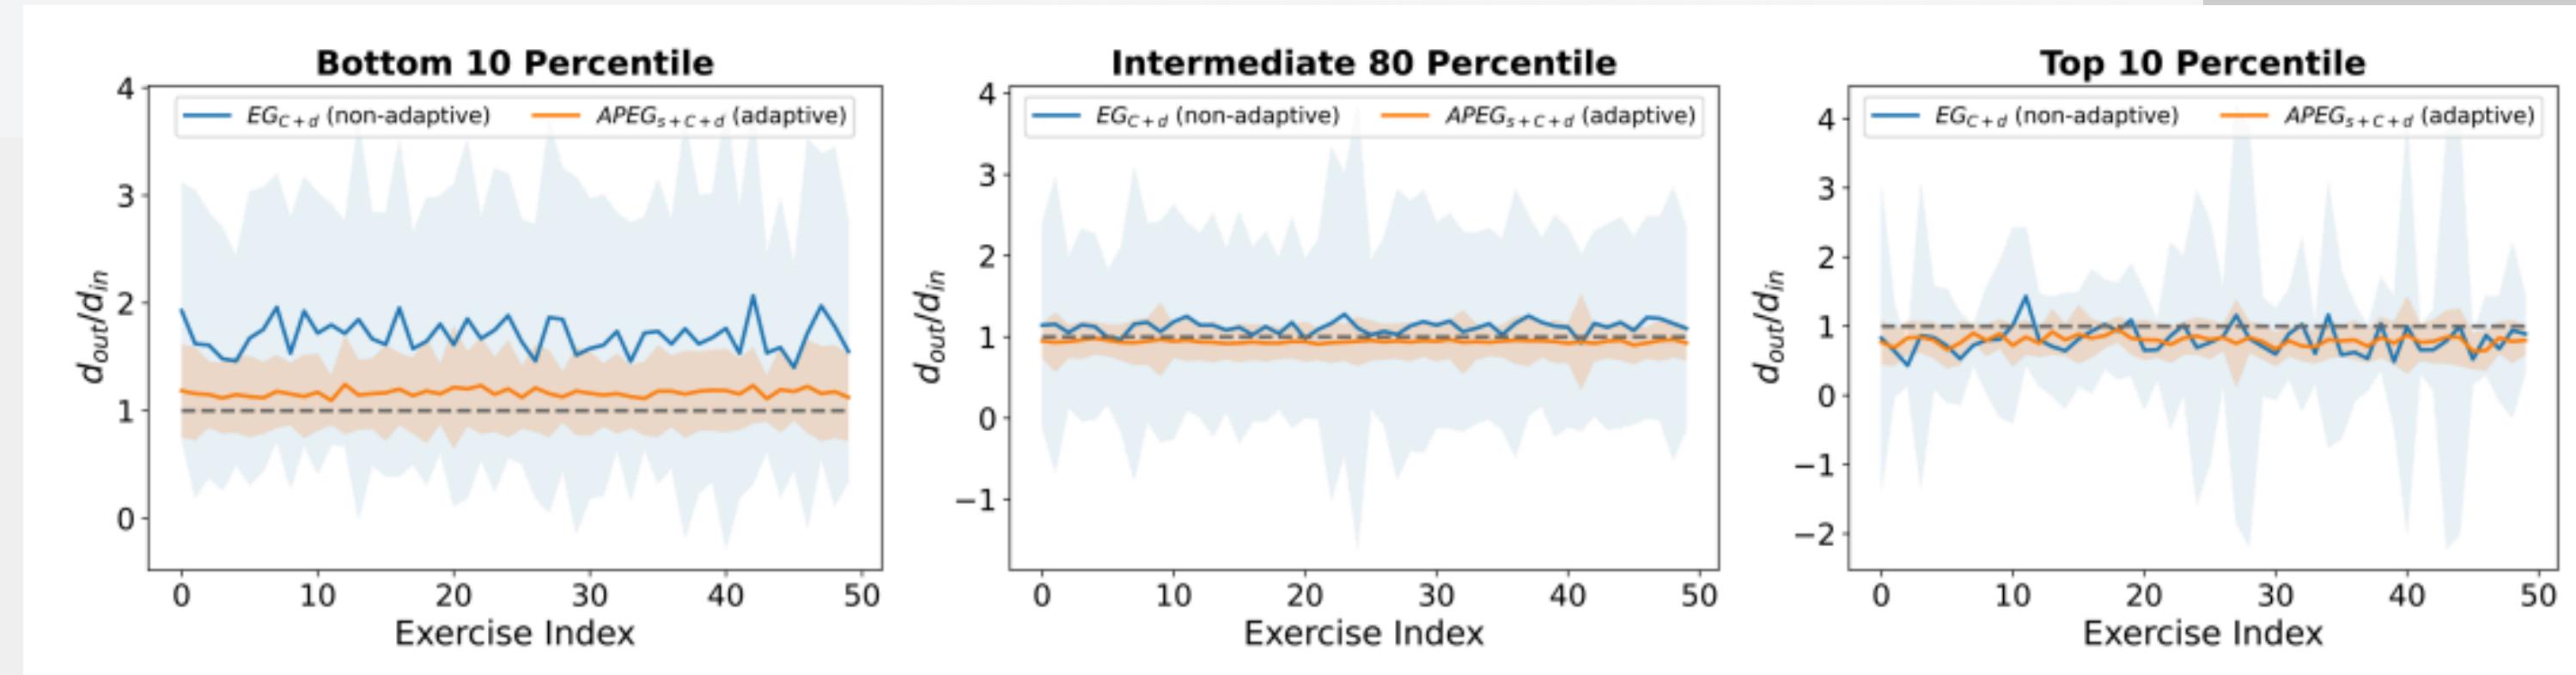
Figure 3: Distributions of accumulated word difficulty in four equally sized segments of 2000 sampled exercise sentences.

4.5 RESULTADOS: ESTUDIO DE GENERALIZACIÓN

- El modelo se evaluó para comprobar su capacidad de generalizar en diferentes dominios de aprendizaje.
- El modelo obtiene un rendimiento superior en las tres tareas evaluadas, con mejores resultados en gramática.
- La generalización en tareas de vocabulario y pronunciación demuestra que el modelo puede adaptarse a diferentes tipos de ejercicios.

d_{in}	Target words	Generated exercises	d_{out}
Avg. knowledge state $\bar{s} = 0.32$			
1.0	{men}	Fifteen <u>men</u> .	1.25
2.0	{study}	I <u>study</u> English.	2.18
3.0	{airport}	Where is the <u>airport</u> ?	2.73
Avg. knowledge state $\bar{s} = 0.65$			
1.0	{profile}	He has a famous <u>profile</u> .	0.94
2.0	{white, bitter}	The <u>white</u> mushroom is <u>bitter</u> .	1.75
3.0	{hit, nail}	She <u>hit</u> the <u>nail</u> on the head.	2.89

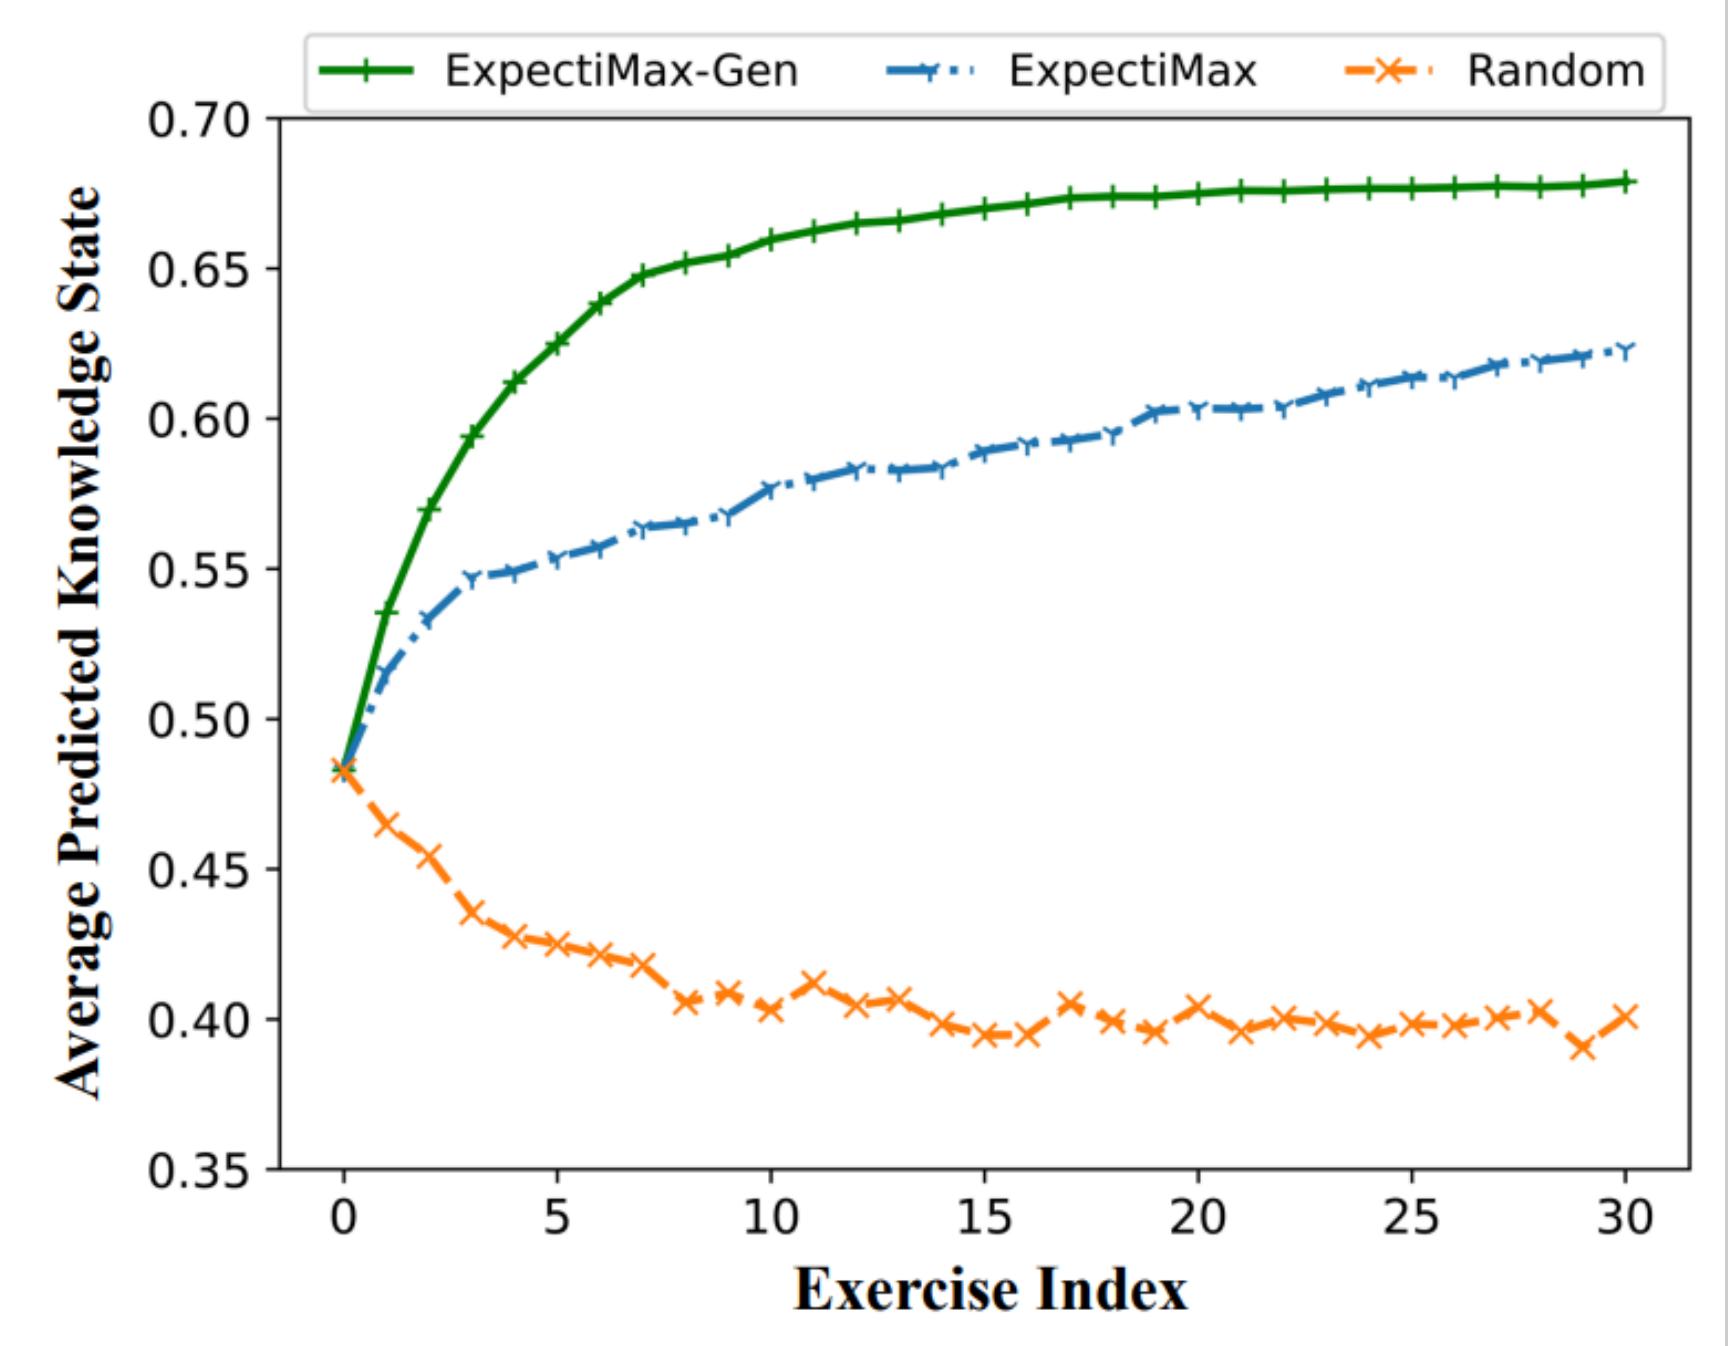
4.6 SIMULACIÓN: AJUSTE DINÁMICO DE DIFICULTAD



- La simulación muestra cómo el modelo ajusta dinámicamente la dificultad de los ejercicios en función del progreso del estudiante.
- El modelo logra una calibración precisa de la dificultad para diferentes niveles de conocimiento.
- Esto asegura que los estudiantes reciban ejercicios ni demasiado fáciles ni demasiado difíciles.
- El modelo se ajusta bien para el 80% de los estudiantes

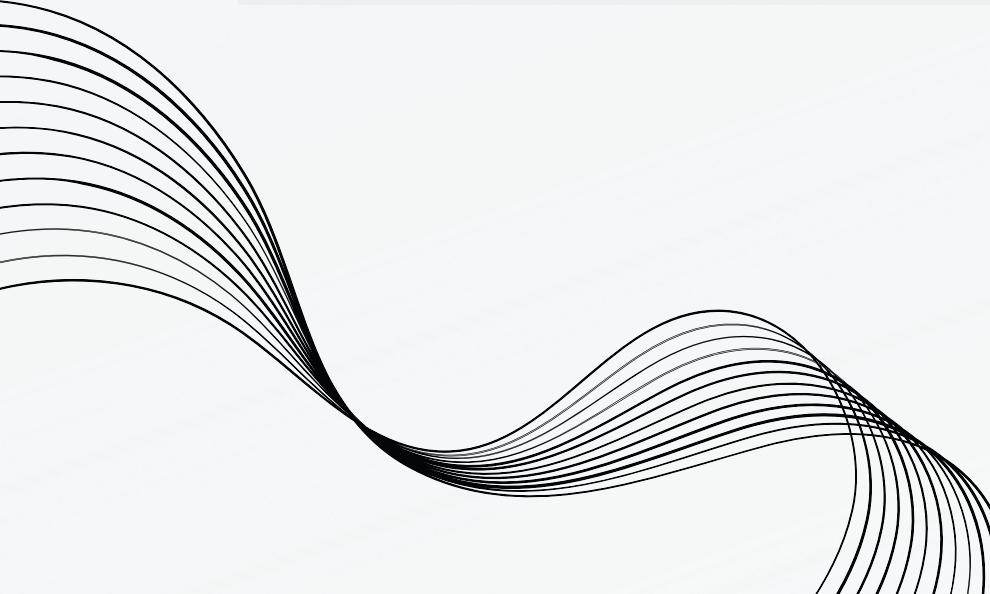
4.7 SIMULACIÓN: MEJORA DE LA EFICIENCIA DEL APRENDIZAJE

- El modelo acelera el progreso del estudiante proporcionando ejercicios personalizados basados en su conocimiento actual.
- Los estudiantes mejoran su conocimiento de forma más rápida con ejercicios adaptados.
- La personalización contribuye a una mayor eficiencia en el aprendizaje.



5.1 CONCLUSIONES GENERALES

- El modelo combina Knowledge Tracing con generación de texto controlada para personalizar el aprendizaje, logrando mejoras significativas en precisión y calidad.
- Mejora en la predicción del estado de conocimiento con el modelo DKLM ($\tau=2$).
- Generación adaptativa de ejercicios con cobertura de más del 99% de los componentes de conocimiento.
- La combinación de rastreo del conocimiento y modelos de lenguaje mejora la personalización en el aprendizaje de idiomas.



5.2 LIMITACIONES DEL ESTUDIO

- Aunque el modelo propuesto presenta mejoras, existen algunas limitaciones.
- La dependencia de grandes cantidades de datos etiquetados para entrenar los modelos.
- El modelo puede no ser efectivo en dominios con menos datos o donde la generación de texto es menos flexible.
- La necesidad de ajustar hiperparámetros y la complejidad computacional del modelo.

